

간행물 등록번호

B552995-016-2019-42-02



식품안전 확보를 위한 식품위험 사전예측 포착시스템 발전방안 연구

식품 빅데이터 분석을 통한 식품안전관리 효율화 방안 마련

조상구·조승용·권소영·최재석



식품안전 확보를 위한 식품위험 사전예측 포착시스템 발전방안 연구

식품 빅데이터 분석을 통한
식품안전관리 효율화 방안 마련

조상구·조승용·권소영·최재석

【공동연구책임자】
조상구 책임연구원
조승용 책임연구원

【공동연구자】
권소영 선임연구원
최재석 박 사

【연구보조원】
최보규 연구원

조상구, 조승용, 권소영, 최재석. (2019). 식품안전 확보를 위한 식품위험 사전예측 포착시스템 발전방안 연구: 식품 빅데이터 분석을 통한 식품안전관리 효율화 방안 마련. 식품안전정보원 연구 보고서.

B552995-016-2019-42-02

**식품안전 확보를 위한 식품위험 사전예측 포착시스템 발전방안 연구
- 식품 빅데이터 분석을 통한 식품안전관리 효율화 방안 마련**

발 행 일 2019년 12월 31일
저 자 조상구 · 조승용 · 권소영 · 최재석
발 행 인 정 윤 희 (식품안전정보원장)
발 행 처 식품안전정보원
주 소 [03127]서울시 종로구 창경궁로 136, 5층(원남동, 보령빌딩)
전 화 대표전화: 02)744-8200
홈 페이지 <http://www.foodinfo.or.kr>
인 쇄 처 엠앤디하나
정 가 비매품

© 식품안전정보원 2019
ISBN 979-11-88824-11-3

발 간 사 <<

4차 산업혁명과 더불어 빅데이터와 인공지능을 핵심으로 하는 지능정보 기술은 현재 우리 삶의 다양한 분야에 보편적으로 활용되어 새로운 가치를 창출하고 있습니다.

식품안전 분야 또한 식품의약품안전처의 통합식품안전정보망이 구축됨에 따라 식품 등 관련 업소의 감시·조사 시, 기존의 관찰과 경험에 의한 식품안전관리에서 벗어나, 데이터 기반의 체계적이고 과학적인 식품안전 관리 기반을 마련하는 것을 지향하고 있습니다.

이의 일환으로 본 연구에서는 식품제도가공업소와 수입식품을 대상으로 통합식품안전관리망의 정보를 활용하여 데이터 분석체계를 마련하고 기계학습을 적용한 부적합 업소 예측모형을 수립하는 것을 목표로 하였습니다. 본 연구의 결과로 도출된 식품제조·가공업소와 수입식품의 부적합 예측모형을 식품안전관리 현장에 적용함으로써 국내 가공식품 및 수입식품의 안전관리를 체계적이고 효율적으로 수행하는데 많은 기여를 할 것으로 기대합니다.

끝으로, 본 연구결과는 식품안전정보원의 공식적인 견해가 아닌 연구진의 개별적인 연구 활동의 결과임을 밝힙니다.

2019년 12월

식품안전정보원장

정윤희

목 차

제 1 장 서론	1
제1절 연구 배경	3
제2절 선행 연구	4
제3절 연구 방법	8
제4절 활용 사례	9
제 2 장 국내 제조·가공업소 선별 단속	15
제1절 연구 목적	17
제2절 통합망 데이터 정제	20
제3절 데이터 시각화	26
제4절 특성변수 추출 및 선택	32
제5절 기계학습 예측모형 적용 및 평가	42
제6절 분류임계값과 재현율	58
제 3 장 수입 가공식품 정밀검사 예측	63
제1절 연구 목적	65
제2절 딥러닝 개요	66
제3절 자료 분석 및 시각화	74
제 4 장 불균형데이터 예측	81
제1절 선행 연구	83
제2절 불균형데이터 기계학습	87
제 5 장 결론 및 제언	99
참 고 문 헌	105

표 목차

[표 1-1] 선행 연구 검토	4
[표 1-2] 기계학습과 통계학의 비교	7
[표 1-3] 통합식품안전정보망 구성	10
[표 1-4] '18년 공공 빅데이터 표준분석 모델	13
[표 2-1] 식품제조·가공업소 감시 및 위반 현황: 2012-2017	20
[표 2-2] 특성변수 후보군 변수와 해당 테이블	22
[표 2-3] 기본정보 항목	33
[표 2-4] 제조 공정	33
[표 2-5] 원재료	34
[표 2-6] 품목 유형	34
[표 2-7] 과거 이력	34
[표 2-8] 환경 요인	35
[표 2-9] 지도점검	35
[표 2-10] 영업자 역량	36
[표 2-11] 특성변수	38
[표 2-12] 관리항목 변수 도출 방법	40
[표 2-13] 관리항목변수 도출 가중치	41
[표 2-14] 예측모형의 성과지표 비교	53
[표 2-15] 정밀도 최대화한 튜닝 예측모형의 Confusion Matrix	60
[표 2-16] 재현율 최대화한 튜닝 예측모형의 Confusion Matrix	60
[표 4-1] 불균형자료의 confusion matrix table	92
[표 4-2] 균형자료의 confusion matrix table	92
[표 4-3] 예측모형의 분류결과표	93

그림 목차

[그림 1-1] 연구 수행 절차도	9
[그림 1-2] 통합식품안전정보망 개념도	11
[그림 2-1] 기계학습 수행 절차도	17
[그림 2-2] 입력변수의 이상치 제거 전후 Box Plot	24
[그림 2-3] 이상치 처리	24
[그림 2-4] 입력변수의 이상치 제거 전후의 히스토그램	24
[그림 2-5] 분석대상 자료의 적합과 부적합 비율	26
[그림 2-6] 2차원과 3차원 주성분분석 그래프	27
[그림 2-7] 다차원 변수 간 상관관계 분석도	27
[그림 2-8] 단일 변수 히스토그램	28
[그림 2-9] 단일 변수 플롯	28
[그림 2-10] 직원대비 품목수와 위반여부 산점도	29
[그림 2-11] 위생관리등급과 위반여부 산점도	29
[그림 2-12] 영업기간과 위반여부 산점도	30
[그림 2-13] 지도점검 회수와 위반여부 산점도	30
[그림 2-14] 급수시설과 HACCP인증여부 vs 위반여부 빈도 그래프	31
[그림 2-15] 급수시설과 영업기간 vs 위반여부 Box-plot	31
[그림 2-16] 행정처분 원인-결과	32
[그림 2-17] 행정처분 원인-결과	37
[그림 2-18] 10겹 교차검증을 위한 데이터	44
[그림 2-19] 훈련데이터세트 및 시험데이터세트	44
[그림 2-20] 문제 해결에 적합한 예측 모형 선택 과정	45
[그림 2-21] 로짓회귀모형과의 비교 평가	46
[그림 2-22] 성과 측정 방법	47
[그림 2-23] 예측모형의 교차검증 정확도	47

[그림 2-24] 예측모형 분류결과표	48
[그림 2-25] 예측모형의 교차검증 f1-score	50
[그림 2-26] 예측모형의 임계치에 따른 부적합판정 확률	51
[그림 2-27] 예측모형의 수신자 조작 특성곡선	52
[그림 2-28] 예측모형 정규화 및 단순분류결과	54
[그림 2-29] 예측모형 PR 그래프(Precision, Recall)	55
[그림 2-30] 예측모형 미래 예측도	55
[그림 2-31] Mcnemar test 등 4 Algorithm Comparison	56
[그림 2-32] 기계학습 연구절차 세부절차도	57
[그림 2-33] 이진분류집단의 제1종·2종 오류의 분포도	59
[그림 2-34] 예측모형 PR 그래프와 수신자 조작 특성곡선	61
[그림 2-35] 임계값과 recall, precesion의 교차곡선	61
[그림 2-36] 임계값에 따른 Recall(검증력)의 변화	62
[그림 3-1] 인간 생체뉴론과 인공지능 뉴론	67
[그림 3-2] XOR 분류 방식	68
[그림 3-3] 딥러닝의 인공신경망 구조도	69
[그림 3-4] keras.team(좌)과 tf.keras(우) 구조	70
[그림 3-5] 인공지능의 활성화 함수	71
[그림 3-6] 인공지능의 활성화 함수를 활용한 XOR 구분도	72
[그림 3-7] 가공식품 정밀검사대상 검사결과	75
[그림 3-8] 데이터의 주성분 분석도	75
[그림 3-9] 제조국(원산지)별 수입신고 종량 및 관세가격	76
[그림 3-10] 수입업소별 수입신고 종량 및 관세가격	76
[그림 3-11] Wide와 Sequential 딥러닝의 구조도	78
[그림 3-12] 기계학습의 기저 분류기 예측모형 AUC결과 AUROC	79

[그림 3-13] Confusion matrix	80
[그림 4-1] 불균형자료의 Under·Over sampling 개념도	87
[그림 4-2] 데이터 수의 증가에 따른 예측모형의 정확도	88
[그림 4-3] 균형과 불균형자료의 PR, ROC곡선 비교도	91
[그림 4-4] Xgbooster 예측모형의 적용 개념도	95
[그림 4-5] 특성변수의 중요도와 평균 중요도	97

Abstract <<

A study on the food fraud detection system as a tool to increase food safety in prevention actions

Cho Sanggoo, Cho Seung Yong, Kwon So Young, Choi Jaesuk

Owing to the increase of FTA, food trade and food import has increased at tremendous rate every year. While the inspection check of imported food is increasing rapidly, the budget and manpower necessary for the government's import inspection control is reaching its limit. The consumer expectations for safety management of processed food manufacturing industries demand a scientific method based on food data to increase the probability of detecting unsuitable food businesses operators.

The intelligent information technology, which is using big data and artificial intelligence, is currently being used universally to add new values in various fields of our lives. Artificial Intelligence technology has solved problems in various fields with the aim of enabling computers to learn in intelligent ways like humans. The purpose of this study is to predict the probability of detecting nonconforming companies by applying machine learning algorithms to food safety

information.

This study applied emerging prediction models in the field of machine learning and proposed new data by pre-processing method as a way to improve the accuracy of the prediction model. This study will give a new way to systematic and scientific food safety management. In the future, it is expected to apply the new anomaly detection model using the predictive model.

The emerging information technology are growing rapidly. MFDS has to endeavour to utilize the current big data and use the super intelligent information technology. The data-driven food management system should be established. The sustainable and specialized competence for data science is requested to establish the governance of systematic data operations.

요약

FTA 체결의 증가, 식품 교역 증가 및 소비자의 다양한 식품 선호도 등으로 농·축·수산물 및 가공식품의 수입량은 매년 증가하고 있는 추세이다. 수입식품의 안전성을 확인하는 정밀검사에 대한 수요는 계속 증가하고 있는 반면에 정부의 수입식품 안전관리에 필요한 예산과 인력은 그 한계점에 다다르고 있다. 국내 가공식품 제조가공업소의 안전관리에 대한 소비자의 기대수준은 증가하고 있어 데이터를 기반으로 효율적인 방안 마련을 위해 부적합이 예상되는 업소를 적발하는 확률을 높이기 위한 과학적인 방법이 필요하다.

빅데이터와 인공지능을 핵심으로 하는 지능정보기술은 현재 우리 삶의 다양한 분야에 보편적으로 활용되어 새로운 가치를 창출하고 있다. 인공지능 기술은 컴퓨터가 인간과 같은 지능적인 방식으로 학습할 수 있도록 하는 것을 목적으로 다양한 분야에서 문제를 해결하고 있다. 본 연구의 목적은 최근의 기계학습 분야의 다양한 개발기술을 식품안전정보에 적용하여 부적합 업체를 단속하는 확률을 예측하는 것이다.

식품 분야 빅데이터의 분석, 분석기법의 적용 등으로 다량의 데이터로부터 의미 있는 정보를 추출하는 과학적이고 자동화된 부적합 탐지시스템의 연구가 절실한 상황이다. 이러한 배경에서 본 연구는 예측모형의 정확도를 개선하기 위한 방편으로 새로운 파생변수의 생성을 통한 데이터 전처리 방안을 제시하였다. 본 연구의 결과로 관찰과 경험에 의한 식품안전관리에서 벗어나 데이터 기반의 체계적이고 과학적인 식품

안전관리 기반을 마련하기를 기대한다. 향후에는 기계학습 분야의 예측 모형을 이용한 부적합 탐지 모형을 적용하여 수입식품의 및 국내 가공식품 안전관리의 국가 사무의 효율성과 수입통관의 신속성에 지대한 효과를 거둘 수 있으리라 기대한다.

정보기술의 발전, 빅데이터의 등장, 분석기법의 고도화 등이 빠르게 성장하고 있어 초지능형 정보기술을 활용하여 이미 확보된 엄청난 양의 식품안전정보에 대한 데이터 검증, 향후 수집정보의 고도화 및 분석과 활용을 위한 데이터 기반의 식품행정 관리시스템을 구축하여야 한다. 지속적이고 효율적인 운영을 위해서는 식약처내 가공식품, 농·축·수산물의 국내 및 수입정보를 총괄하여 관리하는 역할을 담당하는 전문역량과 조직이 필요하다.

제 1 장 서론

제1절 연구 배경

제2절 선행 연구

제3절 연구 방법

제4절 활용 사례

제1절 연구 배경

최근 정보기술의 빠른 발전, 빅데이터의 출현, 분석기법의 고도화, 초지능형 정보가 등장으로 다양한 기술을 활용하여 빅데이터 기반의 과학적인 행정관리 필요성이 증대하고 있다. 식품안전 데이터로부터 데이터 마이닝, 기계학습 모형 등을 적용하여 의미 있는 정보를 추출하고, 과학적이고 체계적인 분석으로 데이터 기반 식품안전 행정사무의 구현, 지속적인 모니터링 등이 가능한 사전예방관리 시스템의 수립이 필요하다.

국내 공공부문 빅데이터 활용 사례 240건 중 식약처의 식품안전 관련 부문은 ‘정부3.0 빅데이터 분석으로 식중독 사전예방 효과 특독’(2015), ‘식중독 예측지도 시범 서비스 실시’(2016) 등 2건에 불과하다¹⁾. 해외에서도 식품안전 데이터를 직접적으로 정책에 활용한 사례는 보고되지 않으며, 식중독 탐지를 위한 빅데이터의 단순 활용 사례가 거의 유일한 사례²⁾이다.

본 연구는 식품영업자의 지도감시, 수입식품의 정밀검사 등 효율적인 운영을 위한 사전예측 시스템의 구축을 목적으로 한다.

1) 남궁근 외(2016)가 대한민국정부포털(www.korea.go.kr) 정부소식란에서 빅데이터 활용 사례 240건을 수집 분석한 결과임

2) 식품안전 분야 데이터가 식품, 건강, 농업 분야에 한정되어 수집되고 또 분산처리 되기 때문이라는 분석(Hans J.P et al., 2017)

제2절 선행 연구

[표 1-1]의 수입식품 사전예측 검사시스템(2014)연구는 로지스틱 회귀분석 모형을 수입 가공식품 정밀검사를 위한 검사시료 무작위 추출에 사용하고 있다. 2016년에는 식품업체의 단속 선별을 위하여 식품업체 위생관리 통계 모델을 개발하였으나, 관련 통계모델의 향상을 위한 지속적인 노력은 부족한 것으로 판단된다.

[표 1-1] 선행 연구 검토

선행연구와의 차별성	
연구제목 및 목적	주요 연구내용
· 수입식품 사전예측 검사시스템(OPERA) · 연구자(연도): 식품의약품안전처(2014) · 연구목적: 다양한 데이터를 회귀분석 방법을 통해 위해도 높은 식품 자동선별, 선별된 품목에 대해 정밀검사를 실시하려는 목적으로 개발	· 과거 수입이력, 부적합정보, 국내외 위해 정보, 국가, 품목, 성분, 수입자 제조자, 해외제조업체 등록 정보 등을 종합분석 · 다양한 데이터의 활용 및 통계적 분석을 통해 위해도 높은 대상을 선별하여 업무 효율성 제고에 기여(무작위정밀검사대상 선별)
· 식품안전정보를 활용한 식품업체 위생관리 통계논리 개발연구 · 연구자(연도): 식품의약품안전처(2016) · 연구목적: 식중독 발생 정보, 기상환경·진료 정보와 함께 사회관계망 서비스(SNS)를 융합하여 알기 쉽게 지역별 발생 위험정보를 지도형태로 시각화하여 제공	· 식중독 발생 정보(식약처), 기상 정보(기상청), 미세먼지(국립환경과학원), 진료 정보(건보공단), 트위터 등 SNS 정보를 활용 · 식품안전 분야 빅데이터 활용의 대표적 사례로 다양한 데이터 통합을 통한 예측, 실시간 정보 수집, 가시성 높은 형태, 수요자 중심 정보 제공 · 활용하는 데이터의 범위가 한정적이어서 단편적 수준에서의 예측 가능성을 나타

선행연구와의 차별성	
연구제목 및 목적	주요 연구내용
	넬 뿐, 실시간 발생현황 탐지 등 식중독 저감화에 직접적으로 활용될 수 있는 수준의 정보를 산출하지 못하고 있음
· 식품안전정보를 활용한 식품업체 위생관리 통계논리 개발연구 · 연구자(연도): 주용성(2016), 동국대학교 통계학과 · 연구목적: 전체 식품관련 업종 중 일반 음식점, 집단급식소, 식품제조가공업에 대한 단속 필요성 점수(위해도) 계산식 마련(로지스틱회귀모델 적용)	· DB정리단계에서 업종별 유용한 변수 후보군을 선별·분리 · 지도점검 및 행정처분자료를 이용하여 통계적으로 예측된 적발확률, 적발내용의 심각성, 그리고 해당 업체의 사회적 영향을 곱하여 산출 · 적발의 심각성 점수는 해당 업체의 행정처분 종류(시정명령, 과태료부과, 영업정지 및 폐쇄)를 예측하고 AHP방법 적용 · 모형의 적용가능성과 전체 업체로의 확대적용을 위한 시뮬레이션 프로그램을 개발
· 수거검사 효율화를 위한 검사필요성 계량화 통계알고리즘 개발연구 · 연구자(연도): 주용성(2017), 동국대학교 통계학과 · 연구목적: 수거검사 필요성 점수 계산식을 개발(로지스틱회귀모델 적용)	· 통합망 자료를 분할, 합산, 그룹화, 수치화하여 수거검사 필요성점수 개발 · 품목(류)별 수거검사 필요성 점수 산출모형 개발을 위하여 예측 수거검사 부적합 확률 모형, 위반내용의 심각성의 정량화 등을 실시 · 제품유형별, 지역별 수거 검사량의 최적 배분을 위하여 통계적 모형에 기반을 둔 기준 제시

본 연구 대상인 업체 지도점검 및 수입식품 정밀검사 결과의 단속 비율은 10% 미만으로 데이터의 유형이 매우 불균형한 형태를 띠고 있다. 부도예측, 카드사고, 이탈고객, 스팸메일, 의료진단 등의 분야에서 나타

나는 불균형데이터에 관한 예측모형 적용은 다수 범주(적합)에 속하는 패턴뿐만 아니라 소수 범주(부적합)에 대한 예측성고를 충분히 고려하여야 한다. 불균형 문제를 해결하기 위한 대표적인 방법으로는 샘플링을 이용한 방법과 오분류를 조정하는 방법이 있다(Kim and Hong, 2014).

의사결정나무 모형, 앙상블모형(Random Forest, Gradient Boosted Trees 등) 등은 나무 형태를 갖는 계층적 구조의 알고리즘으로 다수와 소수 범주의 패턴을 구분하여 예측하는데 적합하다(Galar, et al., 2012). 최근 데이터 마이닝, 기계학습 분야에서 여러 기저 분류기와 관련된 연구는 의학, 금융, 마케팅 부문에서 다양하게 이루어져 왔다(Koufakou and Georgiopoulos, 2010, Otey, et al., 2006). 데이터 불균형 문제는 예측 모형의 성능을 저하시키는 요인으로 작용하고 있으며 이를 해결하기 위해 금융, 의료 및 마케팅 분야에서는 부도예측 및 신용불량자 추출, 희귀한 질병을 가진 환자의 진단 및 이탈고객 방지 등 많은 연구가 이루어지고 있다(Lee and Kwon, 2013; Kang et al., 2004; Mac Namee, et al., 2002).

[표1-2]에서는 기계학습과 통계모형의 차이점인 데이터에 대한 가정 사항과 목적의 차이점을 보여 주고 있다. 선형회귀모형을 예로 들면 통계학에서는 잔차의 평균이 '0'이고 잔차는 상호 독립적이고 분산이 동일한 확률분포를 갖는 확률변수를 가정하여 모든 데이터에 대해 오차 제곱을 최소화하는 선형방정식을 찾는다. 반면 기계학습에서는 훈련과 시험데이터의 구분하여 최상의 예측 성능을 갖는 예측모형을 도출하여 현재 존재하지 않는 추가 데이터에 적용할 경우에 최상의 반복 가능한 예측 결과를 나타내는 것을 목적인다.

[표 1-2] 기계학습과 통계학의 비교³⁾

항목	기계학습	통계학
가정사항	light	heavy
변수	다차원 변수 (Label)	저차원 변수 (Response)
목적	학습(Learning) (다차원변수 예측) → 분류기	추정(Estimation) (인과관계분석) → 가설 검증
응용	실용적 (준지도학습)	학문적 (회귀분석)


본 연구는 국내식품과 수입식품의 안전정보를 활용하여 머신러닝 및 딥러닝 등 빅데이터 기반의 다양한 예측모형을 적용하여 업체 단속대상 선별시스템과 수입식품 정밀검사 사전예측 시스템을 마련하고자 하였다. 또한 통합식품안전정보망의 식품안전정보를 정제하고 부적합 예측 모형의 적용을 통해 사전 예측 모형을 도출하였다.

3) <https://towardsdatascience.com/the-actual-difference-between-statistics-and-machine-learning-64b49f07ea3>

제3절 연구 방법

통합식품안전정보망의 데이터로부터 의미 있는 정보를 추출하고, 데이터마이닝, 기계학습모형 등을 적용하기 위해 식품안전정보의 추출, 합산, 정제, 그룹화 및 시각화 등 자료 전처리 과정을 수행하였다. 통합식품안전정보망의 기존 변수를 바탕으로 다양한 파생 변수(최근 3년 동안 매출액 추이, 종업원대비 품목 보고 수, 사업자 변경 건수, 상호명 변경 건수 등의 발생변수)를 생성하였다. 제조·가공업소의 지도점검 적발과 수입식품의 정밀검사 부적합 결과를 종속변수로 설정하고, 이를 설명하는 다양한 특성(식품업소 및 해외 제조사의 위험도, 수입국의 위험, 품목 유형 등)패턴을 파악하기 위해 상관관계 등 통계분석과 더불어 기계학습과 딥러닝 분야의 다양한 알고리즘 등을 적용하였다.

[그림 1-1]과 같이 통합식품안전정보망의 구조와 내용을 이해하기 위하여 식품안전관리 업종 및 품목에 대한 지도점검, 정밀검사 등 안전관리 지침에 대해 분석하였고, 식품안전관리 업무분석을 위해 현장 인터뷰 등을 수행하였다. 데이터 분석을 위하여 행정처분 및 수입검사 부적합에 영향을 미치는 변수 도출, 단속활동과 부적합과 관련된 시·공간 분석, 식품안전정보 항목의 자료 전처리 등을 통해 예측 모형을 구현하였으며, 예측 모형을 적용하고, 검증하는 순서로 연구를 진행하였다.



[그림 1-1] 연구 수행 절차도

예측모형의 성능이 기대 수준에 미치지 못한 경우에는 식품안전관리 업무의 이해 및 통합식품안전정보망 데이터를 면밀히 재검토하고, 데이터 세트를 구성하여 연구를 반복적으로 수행하였다.

제 4절 활용 사례

식품안전정보는 각 부처에 분산되어 있어 문제 발생 시 타 부처 정보 이용에 한계가 있다. 식품의약품안전처의 통합식품안전정보망은 식품안전관리체계에 따라 분산된 식품안전정보를 연계·통합하여 식품안전정책의 효율성을 높이고 대국민 맞춤형 정보 제공을 목적으로 식품안전기본법 제 24조의 2(통합식품안전정보망 구축·운영)를 법률적 근거로 하여 구축·운영 중이다 ([표 1-3]).

10 식품안전 확보를 위한 식품위험 사전예측 포착시스템 발전방안 연구

[표 1-3] 통합식품안전정보망 구성

시스템명	주요 기능	사용자
식품행정 통합시스템	중앙정부와 지자체간 인허가, 사후관리, 행정처분 정보 등 통합 공유	식약처 지자체
식품정보 활용시스템	12개 부처 159종의 식품안전정보를 통합하여 부처 칸막이 없이 공동 활용	12부처 지자체
식품안전 정보포털	공공정보의 민간 개방·공유 및 대국민(식품업체) 맞춤정보 제공	국민 식품업체

통합식품안전정보망은 ‘행정업무의 통합 및 이관, 정보 공동 활용을 위한 연계 및 대국민 One-Stop 서비스를 위한 국민참여형 식품안전정보포털’로 정의할 수 있으며, 먹거리 관리로 식품안전강국을 구현하기 위해 종합적인 식품안전행정, 신뢰성 있고 일관된 식품안전정보제공, 선제적인 식품안전 대응을 목적으로 [그림 1-2]과 같이 구성되어 있다.

이러한 통합식품안전정보망은 행정업무통합시스템을 통한 식품행정 업무 수행으로 지자체 담당자의 시스템 중복사용 부담을 덜고, 식품안전정보(DB)의 공동 활용을 통해 부처별 식품안전 정책 수립의 효율성을 제고하고 있다. 이에 따라 시·도, 시·군·구 단위의 식품안전정보의 활용 가치가 증대되면서, 지자체로부터 생산되는 통합망의 식품안전 데이터를 활용하여 미래를 예측할 수 있는 선제적 대응체계의 식품안전관리가 가능해졌다.



[그림 1-2] 통합식품안전정보망 개념도

기계학습 기법들은 현재 산업 및 여러 학문 분야에서 다양하게 활용되고 있다. 기계학습, 특히 딥러닝의 활용으로 인하여 기존에 해결되지 못했던 문제들을 해결되었을 뿐 아니라 성능적인 측면에서도 많이 발전하였다. 최근 국내·외 우수 기업들인 구글, 페이스북, 마이크로소프트, 네이버, 삼성, LG, 아마존 등에서 기계학습 및 딥러닝의 기술을 기반으로 한 제품 및 소프트웨어들을 활발히 생산하고 있다(오미애 등, 2017). 또한, AI 및 ML은 온라인 쇼핑에 밀접하게 관련되어 있다. 온라인 쇼핑 구매자의 구매 내역, 인터넷 사용 기록 등이 개인화 되어 공급업체의 이해를 기반으로 제품이나 서비스의 추천(Recommendation)으로 활용되기도 한다.

최근 들어 산업의 경계를 초월하여 각 분야에 기계학습(ML)을 적용하여 비용 효율화 및 수익 극대화를 달성하고 있다. 기계학습(ML)의 실제 산업체 적용 사례는 다음과 같다. 첫째, 사기 방지(Fraud Detection) 적용 분야로 1억5천만 개의 디지털 지갑을 통해 연간 2천 억 달러 이상의 결제를 처리하는 PayPal은 사기 피해 문제를 해결하기 위해 최신 ML 기법을 사용해 사기성 결제를 실시간으로 식별하는 모델을 구축하였다. 둘째, 콘텐츠 추천부문으로 Comcast(주)는 인터랙티브 TV 서비스 고객을 위해 각 고객의 이전 시청 습관을 기반으로 실시간 개인 맞춤 콘텐츠를 추천하고 있다. 수십억 개의 시청자 내역 기록을 사용해 고객별로 고유한 취향 프로필을 작성한 다음, 공통적인 취향을 가진 고객을 군집 분석하여 가장 인기 있는 콘텐츠를 실시간으로 추적하여 추천하고 있다. 셋째, 의료부문으로 Carolinas Healthcare System(CHS)은 환자의 위험 점수를 계산하고 병원 사례 관리자는 이를 바탕으로 퇴원 결정을 내린다. 환자의 건강과 복지도 문제지만 의료보험공단과 민간보험사가 재입실 비율이 높은 병원에 불이익을 주기 때문에 병원의 환자 재입실은 심각한 문제이다. 따라서 향후 건강한 상태를 유지할 가능성이 충분히 높은 환자만 퇴원시키는 사전예측 역량을 높였다. 넷째, 유망고객 확보부문으로 라우터부터 케이블 TV박스에 이르기까지 방대한 제품을 보유한 Cisco의 마케팅 분석팀은 구매 예측 모델을 사용하여 몇 시간 만에 6만 개의 모델을 교육시키고, 1억 6천만 명의 잠재고객을 확보하였다.

Kaggle⁴⁾은 2010년에 설립된 플랫폼으로 기업 및 단체가 해결할 과제를 상금과 함께 등록하면 참가자들이 ML 예측 모형을 개발하여 경쟁

4) <https://www.kaggle.com/>

한다. 2017년에 구글에 의해 인수되었으며, 현재는 타이타닉호 생존자 예측, 미국 아이오와 주의 부동산 가격 예측, 독일 카드회사 사기방지 등 관련 경쟁이 진행 중이다. 2019년 초 공공 빅데이터 신규 분석과제 및 표준분석모델 구축성과 공유를 위해 '18년도의 공공 빅데이터 성과 공유 대회에 발표된 10종의 사례 중 5개를 살펴보면 [표 1-4]와 같다.

[표 1-4] '18년 공공 빅데이터 표준분석 모델

과제명	주요내용	활용데이터
지진 피해지역 지진당일 이동패턴 분석 (국립재난 안전연구원)	· 지진 발생 직후 상황별 대응 요령 도출 · 지진 발생 직후 이동패턴 분석을 통한 지진대응 안내사항 도출 · 대피소 운영 및 제공 구호물자 최적화 방안 마련	· 국가재난 관리시스템 (NDMS) 지진피해 데이터 · 지진대피관련 시설물 및 구호현황 데이터 · 기상데이터 · 유동인구 데이터
쌀 생산량 예측 및 소비 트렌드 분석 (농림축산식품부)	· 농경지 면적정보 및 환경정보 융합을 통한 쌀 생산량 예측 · 소비자 패널조사 정보 및 온오프라인 판매정보 융합을 통한 쌀 소비 트렌드 분석	· 농경지전자지도 · 쌀 생산 소득보전 직불제 정보 · 병해충발생정보 · 상품 판매정보 · 쌀 소비정보 · 쌀 품목별 수출입 실적
농업 면세유류 불법유통 감독 업무 효율화 (국립농산물품질 관리원)	· 지역별 면세유 배정 및 유통현황 파악을 통한 불법 패턴 및 위험도 도출 · 면세유 불법유통 우선 감독 대상 리스트 도출 · 불법유통 근절을 통한 국가 재정 손실 방지	· 농기계 신고 정보 및 산정 배정량 정보 · 면세유 카드 거래 정보 · 면세유 및 일반유 판매가격 정보 · 가축질병정보 · 면세유 대상자 및 배정 정보

14 식품안전 확보를 위한 식품위험 사전예측 포착시스템 발전방안 연구

과제명	주요내용	활용데이터
중소기업 도산 위기 감지를 통한 실업 예방 (국민연금공단/김 해시)	· 중소기업 현황 파악 및 월별 모니터링을 통한 기업 도산 위기 예측 · 중소기업 위기감지(이상탐지) 모델을 활용해 위기 중소기업 대상 선제적 지원 정책 제공	· 제조업체 실태조사 정보 · 지방세/지방세외 미납정보 · 기업재무 및 조기 경보 등급 정보 · 국민연금 사업장 및 가입자 정보
산업재해 원인과 산재은폐 재정 손실 분석 (안전보건공단)	· 산업 내·외부 환경 요인에 따른 산재 발생원인 및 재해자 특성 분석을 통한 산재예방 방안 마련 · 산재 미보고 사업장 패턴 분석을 통해 산재 미보고 사업장 도출 및 건강보험 재정 손실 규모 파악	· 산업재해조사표 정보 · 사업체 동향 정보 · 산재요양신청 정보 · 산재 환수자 정보 · 경제지표 및 사회인구 정보 · 사업자 및 근로자 정보 · 날씨정보

제 2 장

국내 제조·가공업소 선별 단속

제1절 연구 목적

제2절 통합망데이터 정제

제3절 데이터 시각화

제4절 특성변수 추출 및 선택

제5절 기계학습 예측모형 적용 및 평가


제6절 분류임계값과 재현율

2

국내 제조·가공업소 선별 단속 <<

제 1절 연구 목적

본 연구는 가공식품의 제조·가공업소를 대상으로 기계학습의 지도학습(Supervised Learning)예측모형을 적용하여 해당 업체 단속 선별시스템을 마련하여 단속 활동의 효율성을 높이고자 하였다. [그림 2-1]과 같이 본 연구에서는 목적함수의 모델링을 위한 목적정의, 데이터의 기초분석과 시각화, 특성변수 도출 및 예측모형의 선정 및 예측 등으로 기계학습(ML) 수행의 표준적인 절차에 따라 연구를 수행하였다.



[그림 2-1] 기계학습 수행 절차도

종속변수는 2014년도부터 2018년까지 과거 5년 동안 지도점검 적발 건수로 설정하였고, 목적함수는 지도점검이 예상되는 제도가공업체를 사전에 예측하는 것으로 하였다. 지도점검 결과(label $y=1$ if 지도점검 결과가 부적합, or $y=0$ if 지도점검 결과가 적합)에 영향을 미치는 업체 위험, 품목 위험, 환경 위험 및 과거위반 이력 등을 특성변수(Feature)로 도출하고, 다양한 기계학습 예측모형을 적용하여 예측성능이 높은 최적의 모형을 선택하였다. 실제 기계학습 예측모형의 특성변수(X)와 종속변수(y)의 목적함수 및 프로그램 코딩⁵⁾ 입력을 위한 사고를 좀 더 명확히 정립하기 위해 논리식과 단계별 수행 작업은 다음과 같다.

- (1) 목적 정의 : 5년 동안(2014~2018) 식품제조·가공업체 감시 업체
 - (1.1) Labeling : 해당년도에 점검위반내역이 있는 경우 식품 제조·가공업체에는 '1', 없는 경우 '0' 로 표기 (y 값 생성)
 - (1.2) 독립변수(X) : 해당년도에 특정되는 업체의 연도별 *가변적인* 기본사항(생산품목 수, 품목유형 수, 생산실적 등)을 생성

※ 5년 동안 폐업 신고한 업체를 포함하며 업체기준 연도별
패널데이터형태(panel data type) 자료 구조
- (2) 자료 분석 : 탐색적 자료 분석(자료의 시각화, 자료 정리 등 자료 전처리)
- (3) 특성 변수 : y에 영향을 미치는 변수, 파생변수 등을 도출·선택
- (4) 예측모형 : 훈련·시험데이터 구분, 다양한 기계학습 분류기 적용 및 최적화, 예측모형 성과지표의 비교

데이터의 측면에서 본 모델링의 목적은 과거의 식품안전정보(X)에 대한 통계분석과 패턴인식을 통해 적합($y = 0$) 혹은 부적합($y = 1$)인 y의 레이블(Label)에 대한 예측을 목적으로 한다. 즉 업체를 단속할 경우 적

5) Python 3.7과 Keras 2.0을 적용

발이 예상되는 적발 확률인 $P(y=1/X)$ 를 최대화하는 예측모형의 함수를 찾는 것이다.

참고로 기계학습 모델은 생성모델(Generative model)과 차별모델(Discriminative model)로 구분된다. 생성모델은 표본자료(sample dataset)를 생성할 수 있고 차별모델은 생성할 수 없다. 생성모델은 분류 유형에 맞는 표본자료를 생성해 내는 알고리즘으로 생성되는 입력 자료와 결과데이터는 분류유형별로 특정한 통계적 분포를 따른다는 가정을 하고 있다. 차별모델은 조건부확률 $p(y|X)$ 를 직접적으로 반환하여 구분 그 자체를 목적으로 하지만 레이블정보가 필요하다. 차별모델은 생성모델에 비해 가정이 단순하고, 충분한 학습데이터 양으로 우수한 예측성능을 보여주고 있다. 선형회귀, 로지스틱회귀, 서포트벡터모델 등은 차별모델의 대표적인 예이다. 생성모델은 입력데이터(X)가 생성되는 과정을 $p(y)$, $p(X|y)$ 로 정의하고, $p(y|X)$ 를 간접적으로 도출하는 모델이다. 생성모델은 레이블 정보가 없어도 구축할 수 있기 때문에 나이브 베이저안과 같은 지도학습, 가우시안 혼합 모델 등과 같이 비지도학습 기반 예측모델에 적용된다. 생성모델은 y 의 확률분포(probability distribution)를 학습하는 것이 목표이다.

제 2절 통합망데이터 정제

[표 2-1]의 2018년 식품의약품통계연보에 따르면 2017년도에 29,644개의 식품제조·가공업소를 대상으로 감시한 결과 3,070개 업소가 위반하였으며, 감시대비 위반현황 비율은 10.36%이다.

[표 2-1] 식품제조·가공업소 감시 및 위반 현황: 2012-2017

구분	감시(Surveillance)	위반(Violation)	감시 위반율
2012년	30,503	3,018	9.89%
2013년	28,798	3,586	12.45%
2014년	25,658	3,290	12.82%
2015년	29,677	3,639	12.26%
2016년	37,928	3,511	9.26%
2017년	29,644	3,070	10.36%

분석대상이 되는 제조·가공업소의 데이터셋(Dataset)는 통합식품안전정보망에서 추출하여 결측치(missing value) 처리를 거쳐 자료를 합산, 분할, 그룹화, 정규화 등 자료 전처리 작업을 수행하였다. 본 연구의 분석자료 대상은 2013년부터 2018년까지의 5년 동안의 감시 및 위반현황 자료를 토대로 하였다.

1. 자료 추출

통합식품안전정보망에서 제조·가공업소의 지도점검에 해당되는 테이블은 총 69개로 연간 지도·점검 계획에 따라 제조·가공업소를 점검하여 점검실적 및 점검위반사항을 기록한다. 제조·가공업소의 고유 식별은 영업인허가대장번호로 구분되며 매년 정기적으로 생산실적보고를 통해 제조가공업소의 기본 정보사항이 변경되는 패널데이터 특성이 있다. 제조가공업소의 주요 테이블은 점검계획, 점검실적, 영업인허가대장, 생산실적보고 및 행정처분 내역 등으로 구성되어 있다. 관계형 데이터의 테이블 형태로 살펴보면 품목_제조_대장_원재료, 지도점검_계획업소, 생산_실적_보고_업소 및 품목_제조_대장 테이블은 연간 지도점검의 추진, 연간 생산실적보고 등으로 복수의 테이블로 구성되어 있다. 본 연구에서는 품목_제조_대장_원재료에 해당되는 정보는 제외하였다.

2. 결측치 처리

무시할 수 있는 결측치(missing value)인 경우에는 결측치를 제외한 자료만을 대상으로 분석하였다. 자료 수집단계에서 결측치의 수의 최소화로 기계학습부문의 예측모형의 성능을 높일 수 있다. 자료가 null인지 아닌지 여부를 확인하고자 32개 모든 테이블의 변수별로 Notnull, null, 고유값(Unique) 등을 확인하였다.

테이블 확인작업을 통하여 결측치와 이상치를 제외하였고 제조·가공업소의 식품안전관리 업무에 대한 담당자와 인터뷰 등을 통해 최종적으로 17개 테이블을 기계학습 Dataset을 구성하기 위한 후보 테이블과 후보 특성변수로 결정하였다([표 2-2]).

22 식품안전 확보를 위한 식품위험 사전예측 포착시스템 발전방안 연구

[표 2-2] 특성변수 후보군 변수와 해당 테이블


한글명/영문명 table	특성변수 후보변수군
행정처분_양형 ADMSTDSPS_EXAMOFF_001	행정처분_양형_일련번호, 처분내역_일련번호, 처분_유형코드, 처분내용, 처분_정지일자, 최종_수정_일시
영업_인허가_대장 BSN_LCNS_LEDG	영업_인허가_대장_번호, 인허가_번호, 허가_일자, 폐업_일자, 본사_종업원_수, 사무직_종업원_수, 판매직_종업원_수, 생산직_종업원_수, 기타_종업원_수, 건축_면적, 대지_면적, 작업장_총_면적, 기관_코드, 영업소소재지(복사값), 업소명(복사값), 영업대표자명(복사값), 자가_품질_검사_방법
점검실적 CHCKACRST_001	실적_일련번호, 실적_구분코드_F107, 계획_일련번호, 점검원인_유형코드, 업소허가_구분코드_F103, 영업_인허가_대장_번호, 지도점검_일자, 지도점검_결과코드_F020, 형사처분_대상_여부, 지도점검_실적_일련번호, 수거검사_계획제품_일련번호, 국내외_구분코드, 품목_보고_대장_번호, 품목_코드, 등록구분_코드, 시군구_지도점검_일련번호, 품목보고(신고)번호
점검계획 CHCKPLAN_001	계획_일련번호, 계획_제목, 계획_구분코드_F039, 계획_분류코드_F00A, 점검_시작일자, 점검_종료일자, 합동단속_여부, 수립_구분코드_F100, 수립_기관코드, 주요_점검내용, 등록구분_코드, 연제_지도점검계획_번호, 최종_수정_일시, 계획_업무_구분
점검_위반사항 CHCK_VILTMATR_001	위반사항_일련번호, 위반_분류코드, 처분_기준코드, 처분_유형코드, 위반내용, 위반일자, 실적_일련번호, 등록구분_코드, 최종_수정_일시, 위반차수, 위반_법령코드
해당_지도점검_위반사항의 법령 CHCK_VILTMATR_LAWOR D_001	위반사항_일련번호, 법령_일련번호, 위반_법령코드, 실적_일련번호, 최종_수정_일시
처분내역 DSPSDTLS_001	처분내역_일련번호, 실적_일련번호, 처분_상태코드, 업소허가구분(1:인허가,2:무허가), 영업_인허가_대장_번호, 등록구분_코드, 최종_수정_일시
해당_업소의 행정처분내역의 처분사항 DSPSOBJ_VILTMATR	처분대상_위반사항_일련번호, 위반_분류코드, 위반_법령코드, 처분_기준코드, 처분_유형코드, 위반내용, 위반일자, 등록구분_코드, 최종_수정_일시
해당_업소의 행정처분내역의 처분사항의 법령 DSPSOBJ_VILTMATR_LAWO RD	처분내역_일련번호, 처분대상_위반사항_일련번호, 위반_분류코드, 위반_법령코드, 처분_기준코드, 처분_유형코드, 위반내용, 위반일자, 위반차수, 등록구분_코드, 최종_수정_일시, 처분_기준_내용1, 처분_기준_내용2

한글명/영문명 table	특성변수 후보변수군
지도점검_계획업소 GIDCHCK_PLANBSSH_001	계획_일련번호, 지도점검_계획업소_일련번호, 업소허가_구분코드, 영업_인허가_대장_번호, 최종_수정_일시, 처리시점_업종코드
생산 실적_보고_업소 PRDCTN_ACRST_REPORT_DTLS_001	생산_실적_업소_일련번호, 영업_인허가_대장_번호, 평가_년도, 종업원_기술직_인원_수, 종업원_노무직_인원_수, 종업원_사무직_인원_수, 종업원_기타_인원_수, 업체명(당시), 대표자(당시), 영업소재지(당시), 관할기관코드(당시), 사업자번호, 직원수합계, 합계_보고품목수, 합계_연간생산능력, 합계_생산금액, 합계_생산량, 합계_국내판매량, 합계_국내판매액, 합계_해외판매량, 합계_해외판매액
생산 실적_보고_내역 PRDCTN_ACRST_REPORT_BSSH_001	생산_실적_내역_일련번호, 생산_실적_업소_일련번호, 품목_보고_번호, 연간_생산_능력_량, 생산_금액, 생산_량, 국내_판매_량, 국외_판매_량, 국외_판매_금액, 국내_판매_금액, HACCP_여부, 품목유형코드, 품목(제품)명, 상태구분(일반,냉동,레토르트), 생산구분(일반,OEM생산), 유통_판매업체명, HACCP의무대상품목여부, 품목유형명, 품목생산중단일, 생산단위(KG,LT)
품목유형정보 PRDLST_CL	품목_코드, 한글_명, 레벨, 상위_품목_코드, 최상위_품목_코드, 식품군코드, 어린이보호식품여부
품목_보고_대장 PRDLST_MNF_LEDG_001	품목_보고_번호, 품목_코드, 보고(신고)일자, 생산종료_일자, 품목_명, 포장_재질, 영업_인허가_대장_번호
품목제조방법 PRDLST_MNF_LEDG_FOOD_001.xlsx	품목_보고_대장_번호, 용법, 포장_방법, 제조_방법_내용, 보관_방법, 기타
원재료유형코드 RAWMTRL_CD_001.xlsx	원재료_코드, 대표_원재료_명, 부위_코드, 가공_공정_코드, 원재료_상태_코드, 사용_조건_코드
수거검사_계획제품 TKAWYPRSEC_PLANPRDT	계획_일련번호, 수거검사_계획제품_일련번호, 국내외_구분코드, 품목_보고_대장_번호, 수입판매_업체코드, 제품명, 제조업체명, 품목_코드, 제조_국가코드, 등록구분_코드, 최종_수정_일시

폐업 신고한 제조·가공 업소는 영업인허가대장 테이블의 ‘폐업 일자’의 기록이 있는 경우 분석데이터에 포함하였다. 외부 연계데이터인 제조가공업소의 신용등급자료는 본 연구에서 포함시키지 않았다.


3. 이상치 처리

이상치(anomaly data)데이터 제거 방법은 IQR, Z-score, 데이터 변형(표준화, 자연로그 등)을 하거나 구간화(bin), scikit-learn에서 제공하는 outlier-detector를 위해 onclass SVM, Isolation-forest, Local outlierfactor 등이 있다.




[그림 2-2] 입력변수의 이상치 제거 전후 Box Plot

본 연구에서는 자연로그를 취하여 변수의 각 등급 간 분포를 균등하게 하였다.([그림 2-3]) 원자료의 모든 0 값을 Null 값으로 치환하고, 표준편차 -3~3의 범위에 포함된 수치만 필터링한 후 다시 Null 값을 0으로 치환한 후에 자연로그를 적용한 값을 사용하여 예측모형의 성능을 제고(원자료 → 표준화 → 자연로그)하였다.



[그림 2-3] 이상치 처리


총 직원 수와 작업장면적의 변수에 이상치를 제거하기 전후의 히스토그램을 살펴보면 다음과 같다.



[그림 2-4] 입력변수의 이상치 제거 전후의 히스토그램


제3절 데이터 시각화

데이터 시각화(data visualization)는 데이터 분석 결과를 쉽게 이해할 수 있도록 시각적으로 표현하고 전달하는 과정이다. 도표(graph)를 통해 정보를 명확하고 효과적으로 전달하는 것으로 종속변수에 영향을 미치는 특성변수를 살펴보는 데 도움이 된다. [그림 2-5]은 분석대상 자료의 적합과 부적합자료의 비율로 전형적인 불균형데이터를 보여주고 있다. 불균형데이터의 예측모형은 정확도(accuracy)는 의미가 없으며 실제 부적합한 업소 중에서 부적합을 판정하는 비율인 재현율(recall)이 중요하다. 예측모형의 성과인 정확도와 재현율에 대해서는 제5절에서 자세히 설명하고자 한다.




[그림 2-5] 분석대상 자료의 적합과 부적합 비율

주성분 분석(PCA, Principal Component Analysis)은 데이터의 분산을 최대한 보존하면서 서로 직교하는 새로운 기저(Eigen vector)를 찾아, 고차원 공간의 표본들을 선형 연관성이 없는 저차원 공간으로 변환하는 기법이다. [그림 2-6]과 같이 다차원의 특성변수를 2개 또는 3개의 주성분으로 나타내어 부적합과 적합의 구분 여부를 보여 주고 있다.



[그림 2-6] 2차원과 3차원 주성분분석 그래프


변수 간 상관관계는 [그림 2-7]와 같이 양의 상관관계가 높을수록 붉은색으로 나타내었다. 대부분 음의 상관관계가 약하게 나타나고 있고 전체적으로 상관성이 없는 것으로 나타났다.



[그림 2-7] 다차원 변수 간 상관관계 분석도


28 식품안전 확보를 위한 식품위험 사전예측 포착시스템 발전방안 연구

단일변수 시각화를 위해 위생교육실적, 영업기간, 작업장 총면적 및 직원 수를 [그림 2-8]과 같은 히스토그램으로 살펴보았다. 평균 3회의 위생교육실적과 30명 이하의 직원 수를 가진 업소가 대부분인 것으로 나타났다.



[그림 2-8] 단일 변수 히스토그램

범주형 자료인 지도점검 결과에 따른 적합과 부적합을 박스플롯(Box-plot)으로 살펴보면 [그림 2-9]과 같다.




[그림 2-9] 단일 변수 플롯

두 개의 범주형 변수가 서로 상호 작용하는 방식을 보여주기 위해 각 X값에 해당되는 y값의 백분율과 빈도를 원의 크기로 표시하기 위해 [그림 2-10], [그림 2-11], [그림 2-12], [그림 2-13]로 적합과 부적합을 구분하여 직원대비 품목 수, 위생관리등급, 영업기간, 지도점검 회수 등을 산점도로 나타내었다.




[그림 2-10] 직원대비 품목수와 위반여부 산점도




[그림 2-11] 위생관리등급과 위반여부 산점도

30 식품안전 확보를 위한 식품위험 사전예측 포착시스템 발전방안 연구




[그림 2-12] 영업기간과 위반여부 산점도



[그림 2-13] 지도점검 회수와 위반여부 산점도


급수시설 구분여부⁶⁾와 HACCP인증의 두 개의 범주형 자료와 이에 따른 적합과 부적합 그래프를 살펴보면 [그림 2-14]과 같다.

6) 간이상수도, 상수도(음용)지하수(주방용) 겸용, 상수도전용, 지하수전용



[그림 2-14] 급수시설과 HACCP인증여부 vs 위반여부 빈도 그래프

급수시설 구분과 영업기간대비 위반여부의 구분을 Boxplot으로 나타내면 [그림 2-15]과 같다.




[그림 2-15] 급수시설과 영업기간 vs 위반여부 Box-plot

제4절 특성변수 추출 및 선택

1. 특성 변수 추출

제조·가공업소의 지도점검 여부에 영향을 미치는 요인을 생산부터 판매단계까지 전주기적 관점에서 제조 공정, 품목 유형, 원재료, 영업자역량, 과거이력 및 환경요인 등 6가지로 영역으로 구분하였다. 각 영역에 해당하는 후보 특성변수를 확인하여 인과관계 다이어그램(Cause-and-Effect Diagram Method)을 구성하여 [그림2-16]과 같이 나타내었다.



[그림 2-16] 행정처분 원인-결과

[표 2-3] 기본정보 항목

변수명	변수 설명
인허가번호	고유번호(소재지 공장별 영업인허가대장번호) * 영업인허가대장 (BSN_LCONS_LEDG) : 영업인허가대장 번호
주소	공장 소재지 * 영업인허가대장 (BSN_LCONS_LEDG) : 영업소재지(복사값)
시도	주소정보에서 split()
시군구	주소정보에서 split()
위도	Naver 위경도 찾기 API 활용
경도	Naver 위경도 찾기 API 활용
점검여부 (종속변수)	지도점검_결과코드_020(점검실적CHKACRST_001) 0, 1(과거 3년 동안 지도점검에 따른 경과 존재여부) :

[표 2-4] 제조 공정

변수명	변수 설명
인허가번호	고유번호, Primary key
생산능력	합계연간생산능력(생산실적보고업소) 연간생산능력(생산실적보고내역) * 생산 실적_보고_업소 (PRDCTN_ACRST_REPORT_DTLS_001) : 합계_연간생산능력 * 생산 실적_보고_내역 (PRDCTN_ACRST_REPORT_BSSH_001) : 연간생산 능력_량
생산가동률	생산량대비 생산능력 비율 * 생산 실적_보고_내역(PRDCTN_ACRST_REPORT_BSSH_001)의 (생산량 ÷ 연간생산 능력_량)
제조공정 특성	생산 공정 복잡도, 생산주기, 임가공 형태(생산량대비 매출액이 극히 적은 업체) * 임의로 상/중/하로 구분 혹은 원재료유형코드 (RAWMTRL_CD_001) : 가공_공정_코드
생산방식	위탁생산방식(생산실적보고내역), B2B * 생산 실적_보고_내역 (PRDCTN_ACRST_REPORT_BSSH_001) : 생산구분(일반,OEM생산)
판매유통망 구조	품목유형별로 판매유통망 복잡도 정도 * 향후 반영 예정

34 식품안전 확보를 위한 식품위험 사전예측 포착시스템 발전방안 연구

[표 2-5] 원재료

변수명	변수 설명
인허가번호	고유번호, Primary key
원재료위험률	고위험군 원재료의 위험 측정(미생물, 균등) * 원재료 위해를 기준으로 상중하 구분 예정

[표 2-6] 품목 유형

변수명	변수 설명
인허가번호*	고유번호, Primary key
품목유형	원재료의 위험에 따른 품목유형 * 생산 실적_보고 내역 (PRDCTN_ACRST_REPORT_BSSH_001) : 품목유형코드 품목유형정보 (PRDLST_CL) : 품목_코드, 상위_품목_코드 품목_보고_대장 (PRDLST_MNF_LEDG_001) : 품목_코드 등 같은 코드임
품목유형 위험률	원재료의 위험에 따른 품목유형별 risk profiling * 작성 중
원재료 배합 수	품목유형에 투입되는 원재료의 수 * 원재료가 많이 들어가는 품목 유형을 구분하기로 함
생산중인 품목유형	업체별로 생산 중인(생산중단, 종료된 품목보고번호는 제외) 품목보 고번호의 합 생산중인 품목유형은 생산종료_일자를 제외한 모든 품목보고번호기 준의 품목을 유형별로 합산 * 품목_보고_대장 (PRDLST_MNF_LEDG_001) : 생산종료_일자 를 기준으로 생산중 인 제품만 대상으로 Data 구성
다소비식품 유형 구분	생산량기준 국민 다소비 식품 등급 점수(percentile)
품목인증	국가기관에 인증한 인증여부 * 생산 실적_보고 내역 (PRDCTN_ACRST_REPORT_BSSH_001) : HACOP_여부

[표 2-7] 과거 이력

변수명	변수 설명
인허가번호*	고유번호(소재지 공장별 영업인허가대장번호)
과거 지도점검 적발 건수	과거 3년간 지도점검 회수 대비 적발건수의 비율 (업소별)
과거 수거검사 적발 건수	과거 3년간 수거검사 적발건수 for all 품목유형 (업소별)
동일 품목 부적합 적발 빈도	
과거 3년 동안 지도점검 횟수	

[표 2-8] 환경 요인

변수명	변수 설명
인허가번호*	고유번호(소재지 공장별 영업인허가대장번호)
급수시설구분*	간이상수도, 상수도지하수 겸용, 상수도전용, 지하수전용 등 * 영업대장추가정보 (ADMUSER.BSN.LCONS.LEDGLXINFO)의 급수시설구분(새울 :SNT025)
시군구기준 인구밀도*	KOSIS의 행정구역현황(면적)대비 행정구역시군구 인구수 * 면적과 인구수로 인구밀도 계산
시도의 인구통계	외국인 거주 현황, 고령화 등
지도점검 주체 기관	지도점검의 행정관리 주체인 식품의약품안전청, 시도, 시군구
관할지방청	업소가 속한 관할기관 코드(지방식품의약품안전청)
관할청과의 거리	지방식품의약품안전청과 관할권역내 제도가공업소와의 위경도 직선거리

[표 2-9] 지도점검


변수명	변수 설명
계획유형명*	지도점검의 유형
품목유형명*	가공식품의 품목 유형
품목유형 위험도	과거 3년간 수거검사 적발
생산중인 품목유형	- 업체별로 생산중인(생산중단, 종료된 품목보고번호) 품목보고번호의 합 - 생산중인 품목유형은 생산종료_일자를 제외한 모든 품목보고번호기준의 품목을 유형별로 합하여야 함
제품위험도(미정)	위해도가 높은 특정 원재료가 들어간 제품의 빈도와 상관관계 파악

36 식품안전 확보를 위한 식품위험 사전예측 포착시스템 발전방안 연구

[표 2-10] 영업자 역량

변수명	변수 설명
인가번호*	고유번호, Primary key * 영업인허가대장 (BSNLCONS_LEDG) : 폐업일자가 기록된 업소는 제외
영업기간*	영업허가일자부터 현재까지 영업기간(폐업된 업소는 제외) * 영업인허가대장 (BSNLCONS_LEDG) : 허가일자를 기준으로 현재까지 운영일자를 산정
면적*	작업장면적(영업인허가대장), 영업대장추가정보의 영업장면적과 비교 필요 * 영업인허가대장 (BSNLCONS_LEDG) : 작업장 총 면적
직원 수*	사무직인원, 기술직인원, 노무직인원, 기타인원의 합계(생산실적 보고) * 생산 실적 보고 업소 (PRDCTNLACRST_REPORT_DTLS_001) : 종업원 기술직 인원 수, 종업원 노무직 인원 수, 종업원 사무직 인원 수, 종업원 기타 인원 수 등의 총 합
직원 수 대비 품목보고 건수	품목보고번호의 총 합(생산실적보고내역) / 직원 수 * 생산 실적 보고 업소 (PRDCTNLACRST_REPORT_DTLS_001) : 합계 보고품목 수 ÷ 직원 수*
업체 규모 A(종업원 수 기준)	전체 제조·가공업체 대비 Percentile(종업원 수 기준) - 10 등급
HACCP 인증여부	생산실적보고내역과 영업대장추가정보에서 참고
3년 평균 매출액추이 percentile	업체규모 B(매출액 기준)의 등급별로 3년 평균매출액 증감률을 기준으로 해당 업체의 3년 평균매출액 증감률 percentile(평균 매출액은 전년대비 당해 연도 매출액 증감률 2개)
3년 평균 생산량추이 percentile	업체규모 C(생산량 기준)의 등급별로 3년 평균생산량 증감률을 기준으로 해당 업체의 3년 평균생산량 증감률 percentile(평균 매출액은 전년대비 당해 연도 생산량 증감률 2개)
위생관리등급	영업대장추가정보에서 위생관리등급코드(1자율, 2일반, 3중점) * 영업대장추가정보 (ADMUSER.BSNLCONS_LEDG_EXINFO)의 위생관리등급코드 (1자율, 2일반, 3중점)
문제영업자	해당사항 없음
직원 수 기준 백분율	전체 제조·가공업체 Percentile(종업원수 기준) - 10 등급
기업신용평가등급	외부 NICE등에서 유로서비스 API
매출액 기준직원 수 기준 백분율	전체 제조·가공업체 Percentile(매출액 기준) - 10 등급
생산량 기준직원 수 기준 백분율	전체 제조·가공업체 Percentile(생산량 기준) - 10 등급

2014년부터 2018년까지 제조·가공 업소별 위생 점검은 총 62,764건 (위반 총 6,154건)이었고, 위반 비율은 9.80%였다. 업체별 지도점검 및 위반 건수를 연간 지도점검계획에 따라 연도별로 추적하여 자료를 구성하였고(그림 2-17), 구성결과 패널자료(panel data)의 성격을 띠고 있었다.



[그림 2-17] 행정처분 원인-결과

총 75개의 특성변수는 냉동, 레토르트, 일반, 통·병조림의 유형, HACCP 유무, 36개의 품목유형, 작업장_총_면적, 위생관리등급코드, 위생교육실적, 급수시설구분, 시도, 시군구, 위도, 경도, 직원 수 합계, 합계_보고품목 수, 합계_연간생산능력, 합계_생산금액, 합계_생산량, 합계_국내판매량, 합계_국내판매액, 합계_해외판매량, 합계_해외판매액, 대표자변경 여부, 주소변경 여부, 매출액추이, 생산량추이, 영업기간, 점 검 건수, 위반 건수 및 직원대비 품목 수 등으로 구성하였다. 위반여부(위반하였을 경우 '1')를 종속변수로 설정하였다([표 2-11]).

[표 2-11] 특성변수

대분류	특성변수
기본사항	'영업인허가대장번호', '시도', '시군구', '위도', '경도', '작업장_총_면적', '위생관리등급코드', '위생교육실적'
제조공정	제조공정 관련 특성변수는 품목유형으로 대체
원재료	원재료관련 변수는 본 연구범위에서 제외
품목유형	'냉동', '레토르트', '일반', '통병조림', '001', '002', '003', '004', '005', '006', '007', '008', '009', '010', '011', '012', '013', '014', '015', '016', '017', '018', '019', '020', '021', '022', '023', '024', '025', '026', '027', '028', '029', '500', 'C01', 'C02', 'C03', 'D03', 'P01', '기타' 등 36가지 품목유형별 품목제조 보고 수
과거이력	'대표자변경', '주소변경', '매출액추이', '생산량추이', '영업기간',
지도점검	'지도점검 회수', '위반 건수', '지도점검 회수 (t-1)', '위반 건수 (t-1)', '지도점검 회수 (t-2)', '위반 건수 (t-2)', '지도점검 회수 (t-3)', '위반 건수 (t-3)', '지도점검 회수 (t-4)', '위반 건수 (t-4)', '지도점검 회수 (t-5)', '위반 건수 (t-5)'
영업자역량	'품목유형별 HACCP 적용 품목 수', '직원 수', '보고품목 수', '연간생산능력', '생산금액', '생산량', '국내판매량', '국내판매액', '해외판매량', '해외판매액', '직원대비_품목 수',
환경요인	'급수시설구분'

2. 관리항목 변수 선택

특성변수를 도출한 후 어떤 특성변수가 지도점검 위반사항에 유용한 지 아닌지 확인하는 과정을 특징선택(feature selection) 또는 특징 추출(feature extraction)이라고 하며 본 연구에서는 관리항목 변수 선택이라고 정의하였다. 이 과정은 기존 입력을 토대로 새로운 입력데이터를 만들기 때문에 예측모형 적용 전에 이루어져야 한다.

지도점검 결과 위반에 영향을 미치는 관리항목 변수를 도출하기 위해 필터 방법(Filter Methods), 래퍼 방법(Wrapper Methods), 임베디드 방법(Embedded Methods) 등의 방법을 적용하여 전체 산술평균값이 가장 높은 특성변수를 관리항목으로 선택하여 기계학습 모형에 적용하였다.

필터 방법은 일반적으로 전처리 단계로 사용되며 종속 변수와의 상관관계에 대한 다양한 통계량에 의한 통계값을 산출하여 결정한다. 필터 방법은 특성변수에 존재하는 다중공선성을 제거하지 않기 때문에 필터 방법에 의한 관리항목 변수 선택 시 다중공선성을 제거하여야 한다. 래퍼 방법은 특성변수의 부분집합을 사용하여 예측모형을 훈련하기 때문에 이전 모델에서 도출된 추론을 기반으로 특성변수를 추가하거나 제거한다. 임베디드 방법은 필터 및 래퍼 방법을 결합하여 작동하며 기계학습 프로그래밍의 자체 내장된 방법으로 알고리즘이 구현된다. 대표적으로 Lasso 및 Ridge 회귀모형으로 과적합(overfitting)을 줄이기 위해 penalization 함수를 적용하여 관리항목 변수를 도출한 예이다([표 2-12]).

[표 2-12] 관리항목 변수 도출 방법

방법론	관리항목 변수 도출 적용 통계모델
필터방법	Person's Correlation, LDA(Linear Discriminant Analysis), ANOVA, Chi-square 등
래퍼방법	Forward Selection, Backward selection, RFE(Recursive Feature elimination), Boruta package 등
임베디드	Lasso regression L1, Random Forest, LightGBM 등

본 연구에서는 특성변수 72개 중 래퍼 및 임베디드 방법으로 관리항목 변수로 선택이 될 경우에는 '1', 선택되지 않았을 경우에는 '0'을 부여하여 각 특성변수의 총점으로 우선순위를 살펴보았다([표 2-13]). 관리항목 변수는 연간생산능력, 직원 수, 직원대비_품목 수, 지도점검 횟수(t-5), 지도점검 횟수(t-4), 작업장_총_면적, 위생교육실적, 위반 건수(t-2), 위반 건수(t-1), 영업기간, 생산량추이, 매출액추이 등으로 나타났다.

[표 2-13] 관리항목변수 도출 가중치

특성변수	상관관계	Chi-2	RFE	회귀분석	랜덤포리스트	총점
연간생산능력	1	1	1	1	1	5
직원 수(인원수)	1	1	1	1	1	5
직원대비_품목 수	1	1	1	1	1	5
지도점검 횟수(t-5)	1	1	1	1	1	5
지도점검 횟수(t-4)	1	1	1	1	1	5
점검	1	1	1	1	1	5
작업장_총_면적	1	1	1	1	1	5
위생교육실적	1	1	1	1	1	5
위반 건수(t-2)	1	1	1	1	1	5
위반 건수(t-1)	1	1	1	1	1	5
영업기간(연령)	1	1	1	1	1	5
생산량추이	1	1	1	1	1	5
매출액추이	1	1	1	1	1	5
대표자변경 유무	1	1	1	1	1	5
급수시설구분	1	1	1	1	1	5
품목유형 029	1	1	1	1	1	5
품목유형 021	1	1	1	1	1	5
품목유형 014	1	1	1	1	1	5
해외판매액	1	1	1	1	0	4
해외판매량	1	1	0	1	1	4
생산금액	1	1	0	1	1	4
위생관리등급코드	1	1	0	1	1	4
위반 건수(t-4)	1	1	1	1	0	4
냉동식품	1	1	1	1	0	4
HACCP	1	1	1	1	0	4
품목유형 025	1	1	1	1	0	4
품목유형 002	0	1	1	1	1	4
주소변경 유무	0	0	1	1	1	3
지도점검 횟수(t-3)	0	0	1	1	1	3
지도점검 횟수(t-2)	1	0	0	1	1	3

제5절 기계학습 예측모형 적용 및 평가

관리항목변수는 수치형데이터(tumeric data)와 분류형데이터(categorical data)로 구분된다. 수치형데이터의 경우는 '직원 수', '보고품목 수', '연간생산능력', '생산금액', '생산량' 등에 해당되는 변수들이다. 수치형데이터는 스케일링(scale)을 통해 전체 자료의 분포를 평균 '0', 분산 '1'이 되도록 하여 예측모형의 최적화 과정에서 안정성 및 수렴 속도를 향상시킬 수 있다. 분류형데이터는 '위생관리등급코드', '급수시설구분', '대표자변경', '주소변경' 등으로 모두 수치형으로 변환시켜야 하며, dummy 변수 혹은 One-Hot인코딩 방식과 문자열을 정수로 변환시키는 Label Encoder방식이 사용된다.

예측모형을 평가 시 고려해야 할 사항은 (1)예측력: 얼마나 예측을 잘 하는가? (2)해석력: 입력변수와 출력변수와의 관계를 잘 설명하는가? (3)효율성: 얼마나 적은 수의 입력변수로 모형을 구축했는가? (4)안정성: 모집단 내 다른 자료에 적용하는 경우 같은 결과를 주는가? 등의 4가지로 구분된다. 지도점검 단속 결과 예측에서 가장 중요한 고려 사항은 예측력이므로 아무리 안정적이고 효율적이며 해석이 쉬워도 실제 문제에 적용했을 경우 오차율이 큰 모형의 적용은 의미가 없다. 따라서 본 연구에서는 예측모형의 성과 평가를 위해 예측모형의 예측력이 우수한지, 고려된 다른 모형들 중 어느 모형이 가장 우수한 예측력을 보유하고 있는지를 비교, 분석하였다.

기계학습 분야의 예측모형 평가와 모델 선택에서 가장 중요한 것은 “좋은” 예측이다. 훈련데이터에 모델을 학습시키는 것도 중요하지만 새로운 데이터에도 잘 적용되어야 한다. 과거에 입력한 훈련데이터를 단


순히 기억하여 패턴을 인지하는 것이 아니라 한 번도 본 적이 없는 데이터에 대해 좋은 예측을 만드는 것이 무엇보다 중요하다. 기계학습을 적용하고 평가하기 위해서는 사전에 계획을 세우고 목적에 맞는 방법을 사용해야 하며 표준적이고 전형적인 기계학습 절차를 적용하여야 한다. 또한, 기계학습 예측모형의 성능이 새로운 데이터에 얼마나 잘 작동하는지 예측성능을 추정해야 한다. 지도학습(Supervised learning)의 예측모형과 부도예측, 카드사고, 이탈고객, 의료진단 등의 분야에서 나타나는 불균형데이터에 관한 예측모형의 정확도는 다수범주에 속하는 패턴에 대한 정확도 예측성의 척도로는 적당하지 않다.

본 장에서는 민감도(sensitivity), 특이도(specificity), 수신자 조작 특성곡선(ROC, Receiver Operating Characteristic Curve) 등을 산출하여 예측모형의 성과를 비교 측정하였다.

기계학습은 많은 실험을 해야 하는데 예측모형의 내부 설정인 하이퍼파라미터(hyperparameter)를 튜닝하여 훈련데이터셋에 대해 다른 하이퍼파라미터 설정으로 알고리즘을 학습시키면 동일한 예측모형임에도 불구하고 서로 다른 모델이 만들어진다. 본 연구와 같은 불균형데이터의 경우 학습 알고리즘은 예측성능의 편차를 가져온다. 과거 입력 자료를 훈련자료(train data)와 시험자료(test data)로 나누고, 무작위 계층적(random stratified sampling)방식을 적용하였다. 감시결과 위반과 정상 의 각 클래스가 훈련과 시험자료에 정확하게 분포되도록 자료를 랜덤하게 분리한 후 10겹 교차검증(stratified K0-fold cross-validation)을 적용하여 예측모형 추정치의 분산과 편향에 긍정적인 효과를 주었다(Kohavi 1995). [그림 2-18]과 같이 관리항목변수가 포함된 훈련데이터를 대상으로 10겹 교차검증을 통해 기계학습 분야의 다양한 예측모형

44 식품안전 확보를 위한 식품위험 사전예측 포착시스템 발전방안 연구

을 적용하였다.




[그림 2-18] 10겹 교차검증을 위한 데이터

예측모형을 적용하는 표준화된 기계학습 절차는 다음과 같다. 첫째는 예측모형의 결과 신빙성 검증을 위해 데이터를 훈련용(training), 검증용(validation), 시험용(test)으로 분리하는 단계로 예측모형의 과잉 또는 과소 맞춤 등을 방지한다. 가용데이터를 훈련과 시험데이터세트(train and test Data set)로 무작위로 구분한다. 이 중 시험데이터세트는 본 적이 없는 데이터의 역할을 하며, 보통 80%를 훈련 세트로, 20%를 시험 세트로 구성한다([그림 2-19]).



[그림 2-19] 훈련데이터세트 및 시험데이터세트

두 번째는 시험데이터셋을 분리한 후(hold-out) 주어진 문제에 적합한 예측모형을 선택하는 단계이다. 하이퍼파라미터는 모델이 학습하는 동안 학습되지 않기 때문에 이들을 별도로 최적화하기 위한 추가적인 과정이 필요하다. 직관에 따라 정할 수도 있고 또는 머신 러닝 라이브러리를 사용하여 알고리즘에 내장된 기본 값을 사용할 수도 있다([그림 2-20]).




[그림 2-20] 문제 해결에 적합한 예측 모형 선택 과정

기계학습 분야의 다양한 예측모형의 적용과 튜닝 작업 수행 결과 실제 데이터와 예측 데이터를 비교하기 위한 단계로 기계학습의 튜닝인 하이퍼파라미터는 예측모형의 cross_accuracy valuation 값(Error Rate⁷⁾, 1-Accuracy)을 최소화하는 최적의 파라미터를 찾는다. 일반적으로 로짓회귀모형을 bottomline모형으로 하고 다른 예측모형과 비교한다. 로짓회귀모형의 장점은 변수 간 선형상관관계만 고려하며, 모델의


7) <https://arxiv.org/pdf/1811.12808.pdf> Model Evaluation, Model Selection, and Algorithm Selection in Machine Learning, Sebastian Raschka, University of Wisconsin-Madison, Department of Statistics, November 2018

해석과 적용이 용이하다. 반면에 변수 간에 비선형관계가 존재하는 경우에는 예측모형의 성과가 현저히 떨어진다. [그림 2-21]과 같이 두 번째의 입력 자료인 경우에는 비선형관계가 존재하게 되어 로짓회귀모형의 정확도(Accuracy)가 다른 예측모형의 정확도보다 현저히 떨어지는 것을 볼 수 있다. 로짓회귀모형은 설명력은 높으나 관리항목 변수를 사전에 인지하고 있다는 가정을 전제로 하여야 하며 예측모델의 특성상 과적합(Overfitting)하는 경향이 있다.

세 번째는 입력 자료에 적용한 예측모형의 성과를 측정하는 단계이다. 예측모형은 이전에 시험데이터세트를 본 적이 없으므로 새로운 데이터에 대해 편향되지 않는 성능 추정을 가능하게 한다. 각각의 예측모형을 사용해 시험 테스트세트의 클래스 레이블을 예측한 후 예측된 클래스 레이블과 진짜 레이블을 비교하여 성능을 추정한다([그림 2-22]).




[그림 2-21] 로짓회귀모형과의 비교 평가



[그림 2-22] 성과 측정 방법

기계학습 분야의 다양한 예측모형을 적용하여 성능을 추정한 결과 로짓회귀모형의 81.3%보다 상대적으로 높았다.



[그림 2-23] 예측모형의 교차검증 정확도

예측모형의 성과를 나타내는 가장 대표적인 지표는 전체 데이터 중에서 제대로 분류된 데이터의 비율인 정확도(Accuracy, $\frac{TP + TN}{(TP + TN + FP + FN)}$)로 모델이 얼마나 정확하게 분류하는지를 나타낸다([그림 2-23]). 에러율(Error Rate, $1 - \text{Accuracy}$)은 정확도와는 반대로 전체 데이터 중에서

잘못 분류한 비율을 나타낸다. 실제 데이터의 부적합(positive rate)비율⁸⁾이 10%미만인 불균형데이터의 경우에 예측모형의 정확도(Accuracy)는 의미가 없으며 민감도(Sensitivity, Recall)와 정밀도(Precision)가 예측모형의 성과지표를 나타낸다. 본 연구에서는 Ridge 로짓회귀모형으로 관심항목 변수를 정규화(Regularization)한 후에 ExtraTree 예측모형을 적용하였다.

```
#Python Code
pipe = Pipeline([('classifier', ExtraTreesClassifier())])
param_grid = [
    {'classifier': [LogisticRegression()],
     'classifier__penalty': ['l1', 'l2'],
     'classifier__C': np.logspace(-4, 4, 20),
     'classifier__solver': ['liblinear']},
    {'classifier': [ExtraTreesClassifier()],
     'classifier__n_estimators': [16, 32]}
]
clf = GridSearchCV(pipe, param_grid = param_grid, cv = 5, verbose=True, n_jobs=-1)
best_clf = clf.fit(X_train, y_train)
```

		예측(Predicted Class)		
		부적합(Positive)	적합(Negative)	
실제	부적합	True Positive (TP)	False Negative (FN)	Sensitivity $\frac{TP}{(TP + FN)}$
	적합	False Positive (FP)	True Negative (TN)	Specificity $\frac{TN}{(TN + FP)}$
		Precision $\frac{TP}{(TP + FP)}$	적합예측도 $\frac{TN}{(TN + FN)}$	Accuracy $\frac{TP + TN}{(TP + TN + FP + FN)}$

[그림 2-24] 예측모형 분류결과표

8) $P/(P+N)$, $P(=TP+FN)$ 는 실제 데이터의 부적합건수로, $N(=FP+TN)$ 은 실제 데이터의 적합건수, 전체 데이터 수는 $P + N$


[그림 2-24]과 같이 민감도(Sensitivity)는 재현율(Recall or True Positive rate)이라고도 하는데, 실제 부적합인 데이터를 부적합으로 분류하는 비율을 나타낸다. 예를 들면 실제 원본 데이터에 부적합이 100개 있었는데, 예측모형이 90개를 구분하여 분류하게 되면 민감도는 0.9가 된다. 민감도⁹⁾는 예측모형이 얼마나 정확하게 부적합한 업체를 찾느냐를 보여주는 성과척도이다. 정밀도(Precision)는 예측모형이 부적합이라고 예측한 내용 중에 실제로 부적합한 비율을 뜻하는 것으로 예측모형이 얼마만큼 부적합을 맞추느냐에 중점을 두고 있는 성과지표이다. 특이도(Specificity)는 적합으로 예측모형이 판단한 것 중에서 실제 적합인 값의 비율이다.

위양성(false positive)은 본래 적합이어야 하는데 부적합으로 예측한 경우이며, 위음성(false negative)은 본래 부적합이어야 하는데 적합으로 예측한 경우이다. 예측모형의 민감도(Sensitivity)와 정밀도(Precision) 값은 서로 반비례관계에 있으며 두 값을 조화 평균하여 예측모형의 성과척도를 나타내는

F1 점수($F1 = 2 * \frac{(Precision * Recall)}{(Precision + Recall)}$)로 사용한다.

불균형데이터의 경우에는 예측모형의 성과척도로 정확도(Accuracy)보다는 F1 점수(F1-score)가 유용하다. 기계학습 분야의 다양한 예측모형을 적용하여 각 모형의 F1 값을 구한 결과([그림 2-25]) 의사결정나무 및 부스팅 등의 예측모형이 로짓회귀모형이나 가우시안베이지안모형보다 훨씬 높은 값을 갖는 것을 확인할 수 있다.

9) Recall is not so much about answering questions correctly (precision) but more about answering all questions that have answer "true" with the answer "true". So if we simply always answer "true", we have 100% recall.




[그림 2-25] 예측모형의 교차검증 f1-score

[그림 2-26]과 같이 위양성비율(False Positive Rate)과 위음성비율(False Negative rate)은 제1종 오류(Type I errors)와 제2종 오류(Type II errors)이다. 제2종 오류는 귀무가설(H_0 = 실제데이터가 부적합)을 채택하는 오류, 즉 실제 부적합인 것을 적합으로 판정하는 경우로 β -오류이다. 예측모형의 성과지표는 연구목적에 따라 가정 적합한 것을 선정하게 되는데 본 연구의 경우에는 불균형데이터의 특성을 고려하여 위양성 비율(false positive rate)을 낮추고 민감도(Recall)를 높이는 것을 성과척도로 하였다.

β -오류(위음성비율, false negative rate)를 줄이게 되면 민감도(Sensitivity, Recall)는 높아지고 제1종 오류인 α -오류(위양성비율, False Positive Rate)는 높아지게 된다. 예측모형의 하나인 로지스틱모형은 부적합결과와 더불어 해당 데이터의 확률을 0 ~ 1까지 반환하며 예측모형의 분류임계값보다 높은 값은 '부적합'으로 분류하고 분류임계

값보다 낮은 값¹⁰⁾은 '적합'으로 예측하게 된다. 기계학습의 예측모형은 내부적으로 분류 임계값을 0.5로 설정하여 예측결과 값을 산출한다([그림 2-26]). 분류임계값은 연구의 목적에 따라 달라지므로 값을 임의로 조정하거나 해당 예측모형의 파라미터 값을 조정(Hyper-parameter)하여 민감도(Sensitivity, Recall)와 정밀도(Precision)의 값을 최대화하는 분류임계값을 찾을 수도 있다.



[그림 2-26] 예측모형의 임계치에 따른 부적합판정 확률


예측모형의 예측성과를 평가하는 데 사용할 수 있는 측정항목과 해당 분류임계값을 변경했을 때의 내용을 살펴보려면 AUC를 계산하여야 하고, 계산 시 여러 분류임계값(Decision threshold value)에 대해서 재현율(Recall), 정밀도(Precision), 특이도(Specificity) 값을 측정해야 한다.

수신자 조작 특성 곡선(Receiver Operating Curve, ROC)은 모든 분류임계값에서 예측 모형의 성능을 보여주는 그래프로 참양성율($TPR = \frac{TP}{TP + FN}$)과 허위양성률($FPR = \frac{FP}{FP + TN}$)을 2차원 곡선의 형태

10) Python code에서는

로 나타내어 다양한 분류임계값의 참양성율(TPR) 및 허위양성률(FPR)을 나타낸다. 분류임계값을 낮추면 더 많은 항목이 양성으로 분류되므로 거짓양성과 참양성이 모두 증가한다.

[그림 2-27]는 5겹 교차검증(5-fold cross validation)방법으로 DecisionTree 예측모형을 적용한 ROC 곡선을 보여주고 있다. Y축(True Positive rate)의 민감도(Sensitivity)는 실제로 부적합업체 중 부적합 사전예측 가려낼 확률, X축(False Positive rate)의 특이도(specify)는 실제 적합업체 중에서 적합하다고 사전예측을 할 확률에서 1을 차감한 값이다. 수신자 조작 특성곡선을 사용하여 민감도와 허위양성률(1-특이도)을 표현한 그래프로 AUROC의 아래 면적으로 예측모형의 정확도를 알 수 있다. [그림 2-27]의 우상향 45도 직선으로 표시된 임의 예측 모형의 경우 직선 아래의 면적이 0.5이므로 AUROC의 값은



[그림 2-27] 예측모형의 수신자 조작 특성곡선 (Receiver operating characteristics, ROC)


0.5가 되며, 직선의 왼쪽 위에 ROC 커브가 위치할 경우 0.5보다 보다 큰 값을 갖게 되며 반대의 경우는 0.5보다 작은 값을 갖게 된다. AUC 값은 0과 1 사이의 값을 갖게 되며 값이 클수록 좋은 모형이다.

ExtraTree, DecsisonTree 및 Randomforest 의 AUROC 및 F1 Score는 [표 2-14]과 같다.

[표 2-14] 예측모형의 성과지표 비교


예측모형	예측모형 성과 (k_fold = 5)		
	AUROC	정확도(Accuracy)	F1 score
ExtraTree Model	72.52%	90.36%	28.32
DecsisonTree Model	71.21%	89.12%	24.34
Randomforest Model	67.21%	90.12%	23.16

분류 결과표(Confusion Matrix)는 데이터의 적합과 부적합의 결과가 예측한 결과와 일치하는지를 나타내 주는 표이다. 원래 데이터는 행(row)으로 예측한 분류는 열(column)로 나타낸다. [그림 2-28]은 예측 모형의 분류 결과표(Confusion Matrix)를 개수와 비율로 표현한 것으로 정확도(Accuracy)는 85%이며 에러율(Error Rate)은 25%, 민감도(Sensitivity, Recall)와 정밀도(Precision)는 각각 30%와 28%를 보여 주고 있다. 적합인 것 중에서 적합을 맞출 확률인 특이도(Specificity)는 91%이다.




[그림 2-28] 예측모형 정규화 및 단순분류결과

PR 그래프(Precision Recall Plot)는 주로 데이터 분포가 심하게 불균등한 경우에 사용한다. X축을 민감도(Sensitivity, Recall), Y축을 정밀도(Precision), Base line = $P/(P+N)$ 으로 정하는데, P는 실제 데이터의 부적합(Positive)레이블의 수, N 은 적합(Negative)레이블의 수이다. 부적합업체의 실제 양성이 6,154개이고, 전체 데이터의 수는 62,764로 Base line은 $6,154/(6,154+566,610) = 0.98$ 이다. [그림 2-29]은 PR 그래프에 Base line을 적용하여 다양한 모델의 좋고 나쁜 영역을 나타내고 있다. 오른쪽 PR 그래프는 분류임계값의 변화에 따른 민감도(Sensitivity, Recall)와 정밀도(Precision)를 보여 주고 있다.



[그림 2-29] 예측모형 PR 그래프(Precision, Recall)

Precision-recall 그래프는 예측모형의 성능을 파악하기에는 좋으나 여러 예측모형의 성능을 정량적으로 비교하기 위해서는 평균정밀도(AP, average precision)를 계산한다. 평균정밀도(AP)는 예측모형의 성능을 아래쪽의 면적을 계산하여 비교한다([그림 2-29]). 특정 예측모형의 AP가 높으면 높을수록 예측 성능이 우수하다. 물체인식(Object recognition)의 알고리즘 성능은 대부분 AP값으로 평가한다. 민감도나 정밀도를 높이게 되면 분류임계값이 달라지며 단속선별의 목적에 맞는 예측모형의 성과지표를 설정하면 된다. 마지막 단계에서는 새로운 데이터에 대해 모델이 얼마나 잘 작동하는지 추정하여야 한다.




[그림 2-30] 예측모형 미래 예측도

자료에 대한 정규화 및 인코딩이 완료된 총 관리항목 변수를 대상으로 다양한 예측모형을 적용하였다. 결과 값의 확률 분포를 그림으로 보여준다.

```
In [61]: best_clf.best_estimator_.get_params()['classifier']
Out[61]: RandomForestClassifier(bootstrap=True, class_weight=None, criterion='gini',
                                max_depth=None, max_features=6, max_leaf_nodes=None,
                                min_impurity_decrease=0.0, min_impurity_split=None,
                                min_samples_leaf=1, min_samples_split=2,
                                min_weight_fraction_leaf=0.0, n_estimators=40, n_jobs=None,
                                oob_score=False, random_state=None, verbose=0,
                                warm_start=False)
```

[그림 2-31] Mcnerner test 등 4 Algorithm Comparison

```
In [113]: grid={"C":np.logspace(-3,3,7), "penalty":["l1","l2"]}# L1 lasso L2 ridge
In [114]: logreg=LogisticRegression()
In [115]: logreg_cv=GridSearchCV(logreg,grid,cv=10)
In [117]: logreg_cv.fit(X_train,y_train)
Out[117]:
GridSearchCV(cv=10, error_score='raise-deprecating',
             estimator=LogisticRegression(C=1.0, class_weight=None, dual=False, fit_intercept=True,
             intercept_scaling=1, max_iter=100, multi_class='warn',
             n_jobs=None, penalty='l2', random_state=None, solver='warn',
             tol=0.0001, verbose=0, warm_start=False),
             fit_params=None, iid='warn', n_jobs=None,
             param_grid={'C': array([1.e-03, 1.e-02, 1.e-01, 1.e+00, 1.e+01, 1.e+02, 1.e+03]), 'penalty': ['l1', 'l2']},
             pre_dispatch='2*n_jobs', refit=True, return_train_score='warn',
             scoring=None, verbose=0)
```



[그림 2-32] 기계학습 연구절차 세부절차도

제6절 분류임계값과 재현율


지도점검 결과로 나타난 부적합 비율은 10% 미만으로 심한 불균형데이터 형태를 보이고 있다. 부도예측, 카드사고, 이탈고객, 스팸메일, 의료진단 등의 분야에서 나타나는 불균형데이터에 관한 예측모형의 정확도(Accuracy)는 다수 범주에 속하는 패턴에 대한 정확도로 소수범주에 대한 예측성과의 척도로는 적당하지 않다. 불균형자료의 경우 예측모형의 성능은 재현율(Recall)뿐만 아니라 정밀도(Precision)도 중요하다. 예측모형의 분류임계값(Decision threshold)을 높여 예측을 하게 되면 실제 부적합업체에서 부적합이라고 판정할 확률(참양성율)인 재현율은 감소하게 되는 반면 정밀도는 증가하게 된다. 또한 예측모형의 분류임계값(Decision threshold)을 높여 예측을 하게 되면 부적합업체라고 예측된 업체 수는 줄어들고 적합이라고 예측된 업체의 수는 증가하게 된다.

허위양성률(Type I 에러)과 허위음성률(Type II 에러)을 동시에 줄이는 것은 실제 자료의 적합과 부적합자료의 분포가 서로 겹칠 경우, 분포도의 특징 등에 의존하기 때문에 어려운 것이 현실이다. 실제 부적합업체 중에서 부적합이라고 판정할 확률(재현율)을 높일 것인지 부적합이라고 판정한 업체 중에서 실제 부적합업체일 확률인 예측모형의 정밀도를 줄일 것인지는 연구 목적에 따라 다르다. 본 연구에서는 예측모형의 정밀도보다는 실제 부적합업체 중에서 부적합이라고 판정할 확률인 재현율을 높이는 것¹¹⁾을 목적으로 한다.

[그림 2-33]와 같이 수신자 조작 특성곡선(Receiver Operating

11) Type II Error, FNR를 최소화하는 최적화된 예측모형의 발굴

Curve, ROC)의 분류임계값을 오른쪽으로 조정하여 재현율을 최대함으로써 허위음성률(False Negative Error, Type II 에러)을 최소화하는 것을 목표로 하였다.



[그림 2-33] 이진분류집단의 제1종·2종 오류의 분포도와 수신자 조작 특성곡선

본 연구 데이터세트에서 1,255개의 표본을 추출하였고, 이중 부적합률은 10.36%이다. 예측모형을 튜닝하기 위해 가장 높은 재현율을 갖는 예측모형의 성능을 조정(GridSearchCV)한 후에 수신자 조작 특성곡선(Receiver Operating Curve, ROC)과 PR 그래프의 분류임계값을 조정¹²⁾하였다. 예측모형은 RandomForest 예측모형을 적용하였다. 정밀도를 최대화하여 hyperparameter(튜닝)한 예측모형의 정밀도는 100%, 재현율은 6.9%였다.

12) <https://towardsdatascience.com/fine-tuning-a-classifier-in-scikit-learn-66e048c21e65>

[표 2-15] 정밀도 최대화한 튜닝 예측모형의 Confusion Matrix

		예측		
		부적합(Positive)	적합(Negative)	
실제	부적합 (Positive)	9	121	135
	적합 (Negative)	0	1,125	1,125
		9	1,246	1,255

재현율을 최대화하여 hyperparameter(튜닝)한 예측모형의 정밀도는 77.8%, 재현율은 16.2%였다.


[표 2-16] 재현율 최대화한 튜닝 예측모형의 Confusion Matrix

		예측		
		부적합(Positive)	적합(Negative)	
실제	부적합 (Positive)	21	109	135
	적합 (Negative)	6	1,119	1,125
		27	1,218	1,255

재현율을 최대화한 결과에도 불구하고 허위음성률($FNR, \frac{FP}{TP+FN}$)은 정밀도를 최대화한 결과의 $89.6\%(\frac{109}{91+121})$ 에서 $80.7\%(\frac{109}{21+109})$ 로 크게 줄어들지 않았다.


본 연구에서는 scikit-learn의 파라미터의 세밀한 조정을 위해서는 예측모형의 .predict_proba()와 .decision_function()방법¹³⁾을 사용하였다. [그림 2-34] RandomForest의 경우에는 .predict_proba() 방법

을 사용하여 분류임계값을 0.3, 0.5, 0.8인 경우의 PR 그래프를 나타내고 있다.



[그림 2-34] 예측모형 PR 그래프와 수신자 조작 특성곡선


[그림 2-35]과 같이 Recall을 최대화하기 위해서는 어느 정도의 FPR(허위양성률)을 가져야 하는 것을 보여주고 있다.




[그림 2-35] 임계값과 recall, precesion의 교차곡선

- 13) 기계학습의 내장된 분류임계값은 0.5이며 분류임계값을 변경하려면 `.predict_proba()`와 `.decision_function()`을 통해 종속변수의 예측결과 값에 대한 확률을 구해야 함

고정된 임계값에 따른 검증력의 변화¹⁴⁾



임계값에 따른 Recall(검증력)의 변화



[그림 2-36] 고정된 임계값에 따른 검증력의 변화,
임계값에 따른 Recall(검증력)의 변화

14) <https://towardsdatascience.com/choosing-the-right-metric-is-a-huge-issue-99ccbe73de61>

제 3 장

수입 가공식품 정밀검사 예측

제1절 연구 목적

제2절 답러닝 개요

제3절 자료 분석 및 시각화

3

수입 가공식품 정밀검사 예측



제1절 연구 목적

FTA 체결의 증가, 식품 교역 증가 및 소비자의 다양한 식품 선호도 등으로 농·축·수산물 및 가공식품의 수입량은 매년 증가하고 있는 추세이다. 수입식품의 안전성을 확인하는 정밀검사는 전체 수입식품 건수 대비 20% 정도를 차지하고 계속 증가하고 있는 반면에 정부의 수입안전관리에 필요한 예산과 인력은 그 한계점에 다다르고 있다. 수입식품 안전사고가 발생하게 되면 막대한 사회적, 경제적 손실을 초래할 수 있으므로 수입식품의 수입허용 여부를 정확하게 예측하여 선제 대응하는 것은 수입안전관리의 효율성과 경제성을 획기적으로 높일 수 있게 된다. 식품 분야에서는 이미 엄청난 양의 정형데이터가 과거로부터 쌓여 왔으며 이에 대한 충분한 분석을 통한 활용은 아직은 부족한 것이 현실이다.

전체 수입 건수와 중량 중에서 차지하는 가공식품의 비중은 평균 75%에 달하고 있어 식품 분야에서도 빅데이터의 분석, 분석기법의 적용 등으로 다량의 데이터로부터 의미 있는 정보를 추출하는 과학적이고 자동화된 부적합 탐지시스템의 연구가 절실한 상황이다. 이러한 배경에서 본 연구는 최근 인공지능의 한 분야인 신경망모형을 적용하였다. 향후 신경망모형을 이용한 부적합 탐지 모형을 적용하여 수입식품의 정밀검사 비중을 낮추고 부적합률을 제고시킴으로써 수입안전관리 국가사무의 효율성과 수입통관의 신속성에 지대한 효과를 거둘 수 있으리라 기대한다.

제2절 딥러닝 개요

1. 딥러닝 역사


딥러닝은 지난 몇 년 동안 이미지, 오디오, 동영상 등의 인식부문에
보여 주었던 예측 결과의 정확성 때문에 현재는 폭발적인 대중적 인기
를 얻고 있으며 Baidu, Facebook, Google 및 Microsoft와 같은 글
로벌 기업이 관련 기술을 개발하고 있다. 2015년 말, 텐서플로의 공개
와 이를 기반으로 한 구글포토(Google Photos)라는 서비스는 사진들을
자동으로 분류하고 명시적인 라벨 정보가 없어도 검색을 가능하게 해주
는 등 딥러닝 기술의 상용화를 주도하고 있다.

2015년 구글 딥마인드는 CNN(Convolutional Neural Network)을 이
용한 딥러닝 기술과 바둑프로그램으로 널리 쓰이는 Monte Carlo
Tree Search 알고리즘을 사용하여 알파고(AlphaGo)를 선보였다. 유럽
바둑 챔피언이자 중국 프로 바둑기사인 판후이(2단)와 다섯 차례 대국
을 벌여 모두 승리했으며, 2016년에는 우리나라 이세돌(9단)과의 대국
에서도 4승 1패로 승리하였다.

딥러닝은 컴퓨터 비전, 음성 인식 및 자연 언어 처리의 중요한 문제
를 해결하여 인간과 동등한 수준의 컴퓨터에 감각 기능을 제공하고 있
다. 세계적인 컴퓨터 이미지 인식 대회인 ImageNet Challenge에서는
기존 머신러닝 예측모형을 제치고 CNN(Convolutional Neural
Network)을 이용한 딥러닝 기술이 우승하게 되었다. ImageNet
Challenge는 2010년 이래 계속 진행되고 있으며 2015년 기준으로 컴
퓨터 이미지 인식오류율이 5.1%로 추정되는 인간 오류율을 넘어

4.92%의 오류율을 달성하였다.

1943년에 Warren McCulloch와 Walter Pitts¹⁵⁾는 생물인지 분야에서 매우 간단한 생물학적 뉴런(Neuron)을 제시하였고 나중에 인공 뉴런으로 알려지게 된다. 하나 이상의 이진분류 입력과 이로 인해 활성화된 하나의 이진분류 출력에 의한 최초의 인공신경망 모형을 제공하였다. 이후 1957년에 Rosenblatt의 퍼셉트론(The perceptron) 학습 알고리즘에서 퍼셉트론은 두 클래스의 예제를 제시하고 올바른 출력을 내기 위해 퍼셉트론 가중치를 조정함으로써 두 클래스의 객체를 구별하는 방법을 학습할 수 있다는 것을 증명하였다([그림 3-1]).




[그림 3-1] 인간 생체뉴론과 인공지능 뉴론

학계는 퍼셉트론에 대해 낙관적으로 기대했지만 1969년에 Marvin Minsky와 Seymour Papert는 퍼셉트론(perceptron)이 학습할 수 있는 범위에 한계가 있음을 입증하면서 새로운 국면을 맞이하게 됐다. 퍼셉트론 학습이 선형 분리(Linear classification) 문제에는 탁월한 반

15) A logical calculus of ideas immanent in nervous activity, Bulletin of Mathematical Biophysics, Vol. 5, 1943, p. 115-133

면, 비선형 분리(Non-linear classification) 가능성으로 확장하는 방법을 찾지 못했다.


그러나 다중계층퍼셉트론(Multiple Layer Perceptron, MLP)을 사용하여 ‘Exclusive XOR 분류 문제’를 해결하게 되었다. [그림 3-2]는 선형 및 비선형 분리 문제의 차이점을 보여주고 있다. 왼쪽 그림에서 임의의 선은 사각형과 세모를 분리하기 위해서는 무작위로 그려진 임의의 선으로 시작하여 완전히 분리할 때까지 다층구조의 퍼셉트론을 계층화하여 사각형과 세모를 완전히 구분하는 해결 방법을 찾을 수 있게 되었다.



[그림 3-2] XOR 분류 방식

1980년대에 출현한 MLP 네트워크는 역전파학습(back propagation learning)의 개발과 함께 최근까지 이미지 및 음성 신호 등의 분야에 광범위하게 적용되어 오고 있다. 딥러닝은 복수의 은닉층으로 구성된 신경망의 모델로 입력층(Input layer), 복수의 은닉층(Multiple Hidden layers), 출력층(Output layer)으로 구성된다. [그림 3-3]

은 딥러닝¹⁶⁾ 혹은 DNN(Deep Neural Network)의 기본 구조를 보여주고 있다.



[그림 3-3] 딥러닝의 인공신경망 구조도

최근 들어 빅데이터의 출현, 학습 기법의 개선, 초고속 통신망 출현 및 컴퓨팅 성능의 획기적이고 기하급수적인 성장으로 ANN(Artificial Neural Network)인 딥러닝의 기존 한계점을 극복하며 다양한 문제들에 대해 획기적인 성능 향상을 이뤄냈고 앞으로 다가올 4차 산업혁명 시대를 견인할 구동 요인으로 조명되고 있다.


16) <https://www.youtube.com/watch?v=aircAruvnKk&t=458s>

2. 딥러닝 기법

가. 케라스(Keras)

케라스(Keras)는 파이썬으로 구현된 쉽고 간결한 딥러닝 라이브러리로 직관적인 API를 제공하고 있다. 내부적으로는 텐서플로우(TensorFlow), 티아노(Theano), CNTK 등의 딥러닝 전용 엔진이 구동되지만 본 연구에서는 텐서플로우(TensorFlow)기반의 Keras API를 사용하여 개발하였다.

다층퍼셉트론 모델, 컨볼루션 신경망 모델, 순환 신경망 모델 또는 이를 조합한 모델은 물론 다중 입력 또는 다중 출력 등 다양한 구성을 할 수 있다.



[그림 3-4] keras.team(좌)과 tf.keras(우) 구조¹⁷⁾


케라스에서 제공하는 모듈(module)은 독립적이고 가능한 최소 제약 사항으로 서로 연결되며 특히 신경망 층, 비용함수, 최적화기, 초기화

17) Hands-on Machine Learning with Scikit-Learn, Keras & TensorFlow, O'RELLY, sencond edition update for Tensorflow 2

기법, 활성화 함수, 정규화 기법은 모두 독립적인 모듈이다. 또한, 프로그램이 최소주의(Minimalism)를 지향하고 있어 각 모듈은 짧고 간결하며 모든 코드는 한 번 훑어보는 것으로도 이해 가능하다. 다만 반복 속도와 혁신성에는 다소 부족하나 새로운 클래스나 함수로 모듈을 아주 쉽게 추가할 수 있어 확장성이 높다. 케라스를 개발하고 유지보수하고 있는 사람은 구글 엔지니어인 프랑소와 쏘레(François Chollet)이다.


나. 활성화 함수(activation)

활성화 함수란 어떠한 신호를 입력받아 이를 적절한 처리를 하여 출력해주는 함수이다. 임계값을 기준으로 활성화되거나 혹은 비활성화되는 형태를 보이는 Step함수, 항상 0과 1사이의 값만 가질 수 있도록 하는 비선형 함수인 Sigmoid, Sigmoid함수에서 아주 적거나 큰 값을 가질 경우 발생하는 gradient vanishing 문제를 해결하기 위한 ReLU함수, Sigmoid함수와 유사하나 출력 범위가 -1에서 1사이인 Tanh(Hyperbolic Tangent)함수 등이 있다([그림 3-5]).



[그림 3-5] 인공지능의 활성화 함수

0보다 작은 실수에 대해서는 0, 0보다 큰 실수에 대해서는 1, 0에 대해서 1/2의 값을 갖는 heavyside함수와 sigmoid함수를 사용하여 'Exclusive XOR분류 문제'를 풀어보면 아래 [그림 3-6]과 같다. 일반적으로 ReLU함수와 종속변수의 각 class의 score를 받아서 normalized class 확률을 구하는 Softmax함수를 사용하고 있다.



[그림 3-6] 인공지능의 활성화 함수를 활용한 XOR 구분도

다. 에포크(epoch)와 배치사이즈(batch size)

에포크(epoch)는 훈련데이터를 학습하는 주기, 즉 회수를 의미하며 1회 학습은 신경망의 전·후방향을 포함한다. 인공신경망의 파라미터인 weight값은 매 에포크(epoch)마다 업데이트 되어 학습이 일어난다. 배치사이즈(batch size)는 한 번의 학습 시 사용되는 훈련데이터의 수(instance)로 전체 데이터의 수보다 작거나 같다. 배치사이즈(batch size)의 크기는 일반적으로 2의 배수인 2, 4, 8, 16, 32 등을 권장한다. 반복(iteration)은 정해진 batch size를 이용하여 학습(forward + backward)을 반복하는 횟수로 epoch와는 다른 의미이며 한 번의 에

포크(epoch)를 위해 여러 반복이 필요하다.

라. 손실함수(loss function)

손실함수(loss function)는 신경망 학습을 통해 얻은 데이터의 추정치가 실제 데이터와 얼마나 차이가 나는지 평가하는 지표로 값이 크면 클수록 많이 틀렸다는 의미이며 손실함수 값이 0에 수렴할수록 예측모형의 성능이 높아진다. 손실함수의 종류는 평균제곱오차(MSE, Mean of Squared Error), 예측변수가 범주형일 경우 교차엔트로피오차(Cross-Entropy Error) 등이 있다.

마. 역전파알고리즘(Backpropagation)

머신러닝 알고리즘은 경사하강법(Gradient Descent Algorithm)을 이용하여 예측하고자 하는 파라미터(θ)의 초기값부터 손실함수 $J(\theta)$ 를 최소화하는 방향으로 지속적으로 업데이트한다. 이를 수식으로 표현하며 아래 식(1)과 같다.

$$\theta = \theta - \alpha * \frac{\partial}{\partial \theta_j} * J(\theta) \quad (1)$$


인공신경망(Artificial Neural Networks, ANNs)구조에서 이 미분값을 구하기 위해서 첫 번째로 훈련데이터(Training Data)를 입력받아 전 방향 연산(Forwardpropagation)을 수행하여 나온 결과로 예측한 값과 실제 값의 차이인 오차를 계산한다. 두 번째 단계로 오차를 신경망의 각각의 Node들에 역전파연산(Backpropagation)하여 각 노드간의 연결 weight와 bias 값들을 업데이트 한다.

제3절 자료 분석 및 시각화

모집단의 분포 및 변수와 관련된 모델을 가정·가설화하여 표본의 데이터(확률분포, 변수 등)를 통해 모델을 확인하는 전통적인 추론통계학과는 달리 기계학습(Machine learning)은 분포에 대한 모델을 제시하지 않고 과거자료에서 패턴을 파악하고 관련 학습알고리즘(learning algorithm)을 발견하여 컴퓨터에 학습시키는 것이다. 기계학습의 목표는 과거 수입신청 건수 데이터의 패턴을 분석하여 부적합이 예측되는 수입식품을 사전에 예측할 수 있도록 최적화하는 것이다.


1. 분석대상 자료

본 연구의 데이터는 2014년부터 2018년 6월 말까지 총 수입신고 건을 대상으로 하였고, 이중 농·축·수산물을 제외한 식품(가공식품, 건강기능식품, 첨가물, 기구 또는 용기·포장 등)만을 대상으로 하였다. 정밀검사 판정결과가 있는 경우만을 데이터에 포함시키기 위해 수입업소가 자진 취하한 경우, 수입검사원에 의해 반려된 경우, 부분 부적합으로 인한 보류 등은 수입식품의 정밀검사 결과의 판정에 관련이 없어 데이터 구성에서 제외하였다. 결과적으로 식품만으로 구성된 총 262,800건의 자료로 최종 데이터세트를 구성하였다.(그림 3-7).




[그림 3-7] 가공식품 정밀검사대상 검사결과

주성분 분석(Principal Component Analysis, PCA)은 자료의 분산을 최대한 보존하면서 서로 직교하는 기저를 찾아, 고차원 공간의 표본들을 선형 연관성이 없는 저차원 공간으로 변환하는 기법이다. 현재 14개의 특성변수를 2개의 주성분변수로 표현하여 정밀검사 결과인 부적합과 적합을 나타내면 [그림 3-8]와 같다.




[그림 3-8] 데이터의 주성분 분석도

[그림 3-9], [그림 3-10]은 국가 및 수입업소별로 정밀검사 결과별 수입 중량과 가격을 보여주고 있다. 정밀검사 결과 부적합판정을 받은 국가가 수입 중량과 수입가격 등의 상대적 규모가 작다. 부적합판정을 받은 수입업체의 경우도 비슷한 형태를 보이고 있다.



[그림 3-9] 제조국(원산지)별 수입신고 중량 및 관세가격



[그림 3-10] 수입업소별 수입신고 중량 및 관세가격


2. 특성 변수

수입 신고 시 수입식품 등의 수입신고서의 기재사항을 토대로 '수입 중량', '국가별 수입건수', '국가별 수입중량', '국가별 과거 정밀검사 결과', '국가별 과거 부적합률', '품목유형별 수입건수_유형', '수입식품 품목유형별 중량', '품목유형별 정밀검사 결과', '품목유형별 과거 부적합률', '수입국가별 품목유형과 수입건수', '수입국가별 품목유형과 수입중량', '수입국가별 정밀검사결과와 품목유형', '수입국가별 품목유형과 과거 부적합률', '과거 부적합률' 등 14개를 특성변수로 설정하였다. 딥러닝을 적용하기 위하여 categorical 변수는 모두 제외하고 실수값을 갖는 특성변수를 적용하였다. 수입식품의 경우 연간 수입신고 건수가 60여만 건이고 두 변수의 조합에 따른 과거의 부적합률 비율이 예측하고자 하는 수입신고 현황의 해당 부적합 비율과 동일하다는 가정에서 본 분석을 실시하였다.

3. 딥러닝 알고리즘 적용


부적합 수입식품의 데이터의 부적합률은 2,994건으로 전체 수입건수 265,794건 대비 1.13%를 차지하는 불균형데이터 형태를 나타내고 있다. 이러한 극심한 불균형데이터에 대한 예측 모형은 적합으로 판정된 다수의 범주로 패턴 분류를 많이 하게 되어 부적합으로 판정된 데이터인 소수범주는 무시되거나 다수의 범주로 취급하게 되는 경향이 있다. 여러 분류기들의 수신자 조작 특성곡선(ROC, Receiver Operating Characteristic Curve)은 그 성과를 도식화하고 비교하기에 유용하므로 ROC커브의 아래의 면적을 의미하는 AUROC(area under the ROC cuver)를 여러 기저 분류기들의 성과를 평가하는데 사용하였다.

조상구(2018)의 연구에 따르면 Gaussian Naïve Bayes 예측모형의 AUC값이 가장 높게 나타나 예측 모형의 성과가 가장 높은 것으로 나타났다. 본 연구에서는 선행연구의 특성변수에서 분류형 변수를 제외한 실수형 변수로 구성하여 두 개의 딥러닝 모델과 랜덤포리스트 기계학습 예측모형을 적용하여 AUROC의 값을 비교하였다. Wide-Deep 신경망 모델과 순차적 딥러닝 모델을 적용한 모델은 [그림 3-13]와 같이 나타낼 수 있다. AUROC값은 0.914로 기계학습 예측모형인 randomforest의 값과 큰 차이가 없다.




epochs=200, batch_size=16, callback = EarlyStopping(patience=5)

[그림 3-11] Wide와 Sequential 딥러닝의 구조도



[그림 3-12] 기계학습의 기저 분류기 예측모형 AUC결과 AUROC



[그림 3-13] Confusion matrix

제 4 장

불균형데이터 예측

제1절 선행 연구

제2절 불균형데이터 기계학습

제1절 선행 연구

데이터의 불균형문제는 예측 모형의 성능을 저하시키는 요인으로 작용하고 있으며 이를 해결하기 위해 금융, 의료 및 마케팅 분야의 부도 예측 및 신용불량자 추출, 희귀한 질병을 가진 환자의 진단 및 이탈 고객 방지 등 많은 연구가 이루어지고 있다(Lee and Kwon, 2013; Kang et al., 2004; Mac Namee, et al., 2002).

데이터 불균형의 문제를 해결하기 위한 방법으로 데이터 축소(data reduction)기법, 사례 선택기법 등이 있다. 데이터 축소 기법은 데이터 전처리(data reprocessing)기법의 하나로 대량의 데이터에서 가장 대표성이 있는 핵심적인 데이터를 선정하여 원 데이터의 크기를 축소시키는 것이다. 사례 선택기법은 원 데이터를 사용하는 것보다 축소된 데이터를 사용함으로써 원 데이터를 사용하는 것보다 유사하거나 더 나은 예측모형을 도출하는 것이다(García, et al., 2012).

Derrac, et al.(2012)은 사례 선택을 선택하는 방법에 따라 Wrapper 기법과 Filter기법으로 구분하였고 이의 실증을 위해 k-nearest neighbors 기법을 사용하여 학습용 데이터(training data)를 크게 축소하면서도 모형의 성과를 높일 수 있다는 것을 보여 주었다.

샘플링을 이용한 방법과 오분류를 조정하는 방법도 있다. 다수 범주

집단의 데이터를 임의로 샘플링하는 under sampling 방법과 소수 범주 집단의 데이터를 반복적으로 복사하여 샘플링하는 over sampling 방법이 있다(Ganganwar, 2012; Liu, et al., 2006).

과거에 적용되었던 사례와 그 결과를 참조하여 새로운 사례에 적용하는 사례기반추론과 같이 특화된 지식을 활용하여 불균형데이터 문제를 해결하는 방법도 있다(Allen, 1994). 이 이외에도 클러스터링 방법을 통한 데이터 전처리 기법, 유전자 알고리즘을 통해 결합적으로 데이터의 불균형문제를 해결하고자 하이브리드 모형을 적용하여 소수 범주 데이터의 패턴을 찾아내고자 하였다(Hwang, et al., 2007).

정보기술의 빠른 발전, 빅데이터의 등장, 데이터 분석 기법의 고도화 등으로 인해 대량의 데이터를 처리하고 분석하는 연구가 다양한 분야에서 이루어지고 있다(Wu, et al., 2008). 불균형데이터에서는 정확도(accuracy)가 높아도 재현율(recall, 실제 부적합을 부적합이라고 예측할 확률)이 급격히 낮아지는 현상이 발생하게 된다. 본 연구에서는 over-under sampling 방안, SMOTE 방식을 설명하고 불균형데이터 특성을 갖고 있는 수입식품 데이터를 바탕으로 앙상블(ensemble)모형의 하나인 Xgboosting 예측모형을 적용하여 예측성능을 살펴보았다.

적발 예측과 관련된 보험사기, 부도예측, 카드사기 등 실제 현장을 대상으로 한 연구논문은 다음과 같다. K보험사의 2000~2002년 특정 지역 자동차보험 보험금 지급 데이터 사용하여 보험사기의 적발을 위해 기계학습(ML)의 적용(김현수, 2009), 건전 기업과 부도 기업 등 총 45,203건의 재무비율 데이터를 사용하여 단일변량분석 및 다변량분석 과정 등을 이용하여 분석변수를 선정하고 기계학습 모형을 구축(이장우,

권세왕, 2011), 불법현금유통 적발모형 개발에 실시간 처리 상황에서의 적용 가능성을 높이기 위해 6개월간의 실제 거래 자료를 대상으로 신용 카드 불법현금유통 적발을 위한 축소된 앙상블 모형의 구축(이화경 등, 2010)

다수 범주(지도감시 적합의 경우)의 비중이 아주 높은 불균형데이터의 경우에는 FPR(False Positive Rate = False Positives/Total Real Negatives)을 낮추는 것이 굉장히 어렵기 때문에 이런 경우는 ROC보다는 PR 그래프를 예측모형의 성과 기준¹⁸⁾으로 고려하여야 한다. 소수 범주의 데이터 분포가 왜곡(Skewness)되어 있는 경우에도 AUC 이외 다른 지표 들을 고려하여 최적의 예측모형을 선정하여야 한다. 해결방안으로는 첫째 분류기준에 가중치를 부여, 둘째 원본 데이터에서 resampling(over or under sampling, 사례 선택 혹은 특징변수 선택), 셋째 분류모형에 차별로직 부여 등¹⁹⁾이다.

분류기준에 가중치를 부여 방식은 오분류 비용(Misclassification Cost)을 사용하는 것으로 즉 소수 범주에 대한 오분류에 다수 범주에 대한 오분류보다 더 큰 오분류 비용을 적용하는 것이다. 이는 원래 데이터 분포를 왜곡시키지 않는 장점이 있는 반면에 데이터 불균형이 심할 경우에는 샘플링 방법에 비해 효과가 적다는 단점(강필성 외 2인, 2005; 허준 김종우, 2007)이 있다. 원본 데이터에서 Resampling하는 방법으로 첫째, 소수 범주의 수에 맞추어 다수 범주의 데이터를 추출하는 언더샘플링(Under-Sampling)방법인데, 다수 범주에서 추출되는 데이터에 의해 모형 성능이 크게 영향을 받는 단점이 있으므로 소수 범주의 수가

18) <https://www.kaggle.com/lct14558/imbalanced-data-why-you-should-not-use-roc-curve>


19) Strategies for learning in class imbalance problems, 2002

매우 적은 경우에는 좋은 결과를 얻을 수 없다. 둘째는 다수 범주로부터의 추출할 표본 크기를 정하고 이에 맞추어 소수 범주로부터 추출하는 오버샘플링(Over-Sampling)방법으로 오버샘플링을 위해서 복원추출 또는 부족한 소수 범주의 데이터를 인공적으로 생성하는 방법이 사용되는데, 데이터 수가 증가하므로 학습 시간이 증가한다는 단점이 있다(Chawla et al., 2002; Guo and Viktor, 2004). 대부분의 논문에서는 Random or K-cluster over sampling 및 SMOTE(synthetic minority oversampling technique) 방법 등을 데이터에 적용하여 예측모델의 성과 제고를 위해 노력하였다.

제2절 불균형데이터 기계학습

1. Over & Under sampling

오버샘플링(Over sampling)은 무작위로 소수의 데이터를 사전에 기준을 정해서 복제하는 방법으로 정보가 손실되지 않는다는 장점이 있으나, 여러 유형의 관측치를 다수 추가하여 과적합(overfitting)을 초래할 수 있는 단점이 있다. 이러한 경우 훈련데이터의 성능은 높으나 시험데이터의 성능은 줄어든 가능성이 있다. 소수 데이터를 단순 복제하기 보다는 유의한 데이터만을 남기는 방식으로 기계학습의 알고리즘으로 Easy Ensemble, Balance Cascade 방식 등을 적용하기도 한다. 반면에 언더샘플링(Under sampling)의 경우 데이터의 소실이 매우 크고, 때로는 중요한 정상데이터를 잃게 될 수 있는 위험이 존재한다.




[그림 4-1] 불균형자료의 Under·Over sampling 개념도

기계학습 학습곡선에서 기대할 수 있는 일반적인 특성은 다음과 같다. 첫째, 동일한 예측모형에서 데이터의 크기가 적을수록 훈련데이터의 정확도는 높은 반면 검증데이터의 정확도는 작아지게 되어 데이터의 크기

와 과적합(Overfitting)은 반비례의 관계를 갖는다. 둘째, 예측모형은 우연한 경우를 제외하고 검증데이터보다 시험데이터에 높은 정확도를 제시하지는 않으며 데이터의 크기가 아무리 커져도 검증데이터와 훈련데이터의 정확도 곡선이 교차되는 경우는 절대 발생하지 않는다.

[그림 4-2]와 같이 데이터의 크기가 적을 경우에는 훈련데이터와 검증데이터의 예측모형 정확도가 차이가 커서 분산(variance)이 크다. 반면에 데이터가 커질수록 분산이 줄어들어 예측성능이 개선된다.



[그림 4-2] 데이터 수의 증가에 따른 예측모형의 정확도

데이터의 특성이나 확보 데이터량에 따라 오버 혹은 언더샘플링 방식을 선택하게 되지만 일반적으로 실무에서는 많은 데이터 확보가 효과적이므로 오버샘플링 기법을 적용하는 것을 권장한다. 오버샘플링의 방법으로 SMOTE(synthetic minority oversampling technique)는 소수의 범주에 속하는 자료에 kNN, Borderline-SMOTE, ADASYN 등의 방법론을 적용한다.

분류형 자료는 One-hot인코딩(dummy인코딩)과 label인코딩방식으로 자료변환을 하게 된다. 다만 입력변수의 개수가 많은 경우에는 One-hot 인코딩을 적용하면 입력변수의 차원을 높이는 단점이 발생하고 label 인코딩방식은 입력변수에 무작위로 순서를 부여하는 한계점을 갖고 있다. 분류형 입력변수의 수가 많고 자료 형태가 기수적(cardinal number)일 경우 Mean-Target 인코딩 방식에 Regularization을 적용한 K-fold Target 인코딩을 사용하게 된다. Mean-Target 인코딩 방식 훈련데이터와 시험데이터의 분포 형태가 서로 다를 경우에는 과적합(overfitting)이 발생하게 되는데 K-fold Target인코딩을 적용하면 과적합(overfitting)을 방지할 수 있다. 본 연구에서는 분류형 자료는 제외하고 실수형 자료에 대한 예측을 수행하였다.


2. 예측모형 성과척도

예측모형의 성과는 AUROC, AP, recall, precision, f1-score 등을 활용한다. ROC 그래프는 서로 다른 확률 임계값(probability thresholds)을 사용하여 참양성비율(true positive rate)과 허위양성비율(false positive rate)의 트레이드오프(trade off)를 나타낸다. PR 그래프는 서로 다른 확률 임계값(probability thresholds)을 사용하여 참양성비율(true positive rate)과 예측모형의 참양성비율의 트레이드오프(trade off)를 나타낸다. ROC 곡선은 관측치가 각 클래스 사이에서 균형을 이루는 경우에 적합하지만 PR 곡선은 불균형 데이터 세트에 적합하다. 불균형데이터의 경우에는 전체 적합한 자료 중에서 적합한 자료를 예측하는 특이도(Specify)에 대한 잘못된 시사점으로 ROC 곡선보다는 PR 곡선을 사용하여야 한다. PR 곡선은 예측모형의 참양성비율을

나타내고 불균형자료, 특히 이진분류의 경우에는 PR 곡선이 ROC 곡선 보다는 직관적이고 정확한 가시성을 보여주고 있다(Takaya, 2015, Fu, 2019).

[그림 4-3]에서는 적합과 부적합의 비율이 불균형인 자료와 균형인 자료에 대한 ROC 곡선과 PR 그래프에 대한 사례를 제시²⁰⁾하였다. 표본 수 1,000개를 이진분류를 위한 무작위 자료 형태로 하여 불균형(90:10)과 균형(50:50)자료로 만들었다. 불균형자료의 경우에는 대부분의 90%를 차지하는 적합자료(negative data)중에서 적합(negative)이라고 판정한 자료가 많기 때문에 불균형자료의 적합과 부적합비율에 영향을 전혀 받지 않는다(Saito, 2015).

20) <https://machinelearningmastery.com/roc-curves-and-precision-recall-curves-for-classification-in-python/>



[그림 4-3] 균형과 불균형자료의 PR, ROC곡선 비교도

불균형과 균형자료의 혼동표(Confusion matrix table)를 살펴보면 [표 4-1], [표 4-2]와 같다.

[표 4-1] 불균형자료의 confusion matric table

	정밀도 (precision)	재현율 (recall)	f1 값	support
적합(negative)	0.92	0.97	0.94	447
부적합(positive)	0.44	0.21	0.28	53
micro avg	0.89	0.89	0.89	500
macro avg	0.68	0.59	0.61	500
weighted avg	0.86	0.89	0.87	500

불균형자료에 대해 예측모형을 적용하지 않고 무작위예측을 할 경우인 dumm예측모형을 적용할 경우에는 적합자료에 대한 정밀도, 재현율, f1값은 0.89이며 부적합자료의 경우는 0.07, 0.08, 0.07이다. 균형자료에 대한 무작위예측모형의 성능척도는 모두 0.5이다.

[표 4-2] 균형자료의 confusion matric table

	정밀도 (precision)	재현율 (recall)	f1 값	support
적합(negative)	0.80	0.78	0.79	240
부적합(positive)	0.80	0.82	0.81	260
micro avg	0.80	0.80	0.80	500
macro avg	0.80	0.80	0.80	500
weighted avg	0.80	0.80	0.80	500

불균형자료의 혼동표를 정규화하지 않고 전체 자료 1,000개를 기준으로 나타내면 [표 4-3]과 같다.

[표 4-3] 예측모형의 분류결과표

실제 \ 예측	적합	부적합	소계	정밀도 (precision)	재현율 (recall)
적합	873	79	952	0.92(=873/952)	0.97(=873/900)
부적합	27	21	48	0.43(=21/48)	0.21(=21/100)
소계	900	100	1,000		
micro avg				0.89(=(873+21)/1000)	0.89(=(873+21)/1000)
macro avg				0.68(=(0.92+0.43)/2)	0.58(=(0.97+0.21)/2)

수입식품과 같이 극심한 불균형자료 유형에서는 예측모형의 성능 비교 시 macro avg의 성능지표가 적합하다²¹⁾.

3. GBM 예측모형


최근의 Kaggle 경진대회²²⁾에서 우승자들의 대부분이 GBM(Gradient Boosting Method)예측·모형을 사용하였다. GBM은 병렬처리 방식을 사용하여 학습과 분류가 빠르고 평가함수를 포함하여 다양한 최적화 옵션을 사용할 수 있어 아주 유연하다. Xgboost와 다른 기계학습 알고리즘을 연계·결합하여 앙상블(Ensemble)학습이 가능하다.

부스팅(boosting)은 약한 분류기인 의사결정나무(weak decision tree)를 순차적으로 세트로 구성(greedy-algorithm을 사용한 가지치기)하여 과적합(Overfitting)이 잘 일어나지 않도록 예측하는 방법²³⁾이다. GBM은 의사결정나무를 교육하여 작동하는 앙상블 방법이나 병렬처리

21) Macro- and micro-averaged evaluation measures(BASIC DRAFT)
22) www.kaggle.com
23) <https://www.kaggle.com/willkoehrsen/intro-to-model-tuning-grid-and-random-search>

방식을 취하는 randomforest방식과는 달리 후행 분류기가 선행분류기부터 학습하는 순차적 기계학습모형이다. 따라서 수백 또는 수천 개의 약한 분류기가 결합된 Gradient Descent(개별 분류기의 가중치가 예측모형의 매개 변수)를 사용하여 전체적으로 강력한 앙상블(Ensemble) 학습을 발생시킨다. 따라서 딥러닝의 파라미터와 마찬가지로 아주 많은 파라미터를 조정(tuning)하여야 하며 early stopping기능을 적용하기도 한다.

GBM은 실제 값 y 와 1차 회귀선의 결과 값인 $h_1(X_1)$, $h = (X^t X)^{-1} X^t Y$ 와의 차이인 잔차항(residual error term)을 순차적으로 계속 회귀모형을 적용하여 최종적으로 잔차항이 '0'에 수렴하도록 한다. [그림 4-4]와 같이 왼쪽 열의 그림은 잔차항에 대해 회귀모형을 적용하여 계속 줄여 나가는 그림이고 오른쪽 열의 그림은 $h_1(X_1), h_2(X_1), h_3(X_1)$ 의 값을 가중평균하여 예측모형을 적용한 결과를 붉은색의 가중평균 회귀모형을 보여주고 있다.



[그림 4-4] Xgboost 예측모형의 적용 개념도

본 연구에서는 GBM을 적용하기 위하여 LightGBM 라이브러리를 사용하여 수입식품데이터에 적용하여 예측하였다. LightGBM은 scikit-learn에서 제공하는 빠르고 효율적인 GBM예측모형이다. 과적합(Overfitting)을 방지하기 위해 5 K-fold를 사용하여 early_stopping_rounds = 100을 설정하여 LightGBM의 다양한 파라미터에 대한 Grid search의 결과는 아래와 같다. AUROC와 AP(Average precesion)의 값은 각각 91.59%, 21.41%로 예측성능 값을 보여 주고 있다.

Hyperparameter grid-search 준비

```
param_grid = {'boosting_type': ['gbdt', 'goss', 'dart'],
              'num_leaves': list(range(20, 150)),
              'learning_rate': list(np.logspace(np.log10(0.005), np.log10(0.5), base = 10, num = 1000)),
              'subsample_for_bin': list(range(20000, 300000, 20000)),
              'min_child_samples': list(range(20, 500, 5)),
              'reg_alpha': list(np.linspace(0, 1)),
              'reg_lambda': list(np.linspace(0, 1)),
              'colsample_bytree': list(np.linspace(0.6, 1, 10)),
              'subsample': list(np.linspace(0.5, 1, 100)),
              'is_unbalance': [True, False]}
```


Hyperparameter grid-search 결과

```
param_grid = {'boosting_type': 'gbdt',
              'colsample_bytree': 0.6,
              'is_unbalance': True,
              'learning_rate': 0.0049,
              'min_child_samples': 20,
              'n_estimators': 639,
              'num_leaves': 20,
              'reg_alpha': 0.0,
              'reg_lambda': 0.0,
              'subsample': 0.5,
              'subsample_for_bin': 20000}
```

로짓회귀분석과 같은 선형모형은 선형식으로 설명이 가능하지만 비선형적인 모델인 LightGBM의 경우에는 SHAP의 개념을 가지고 표현할 수 있다. SHAP(Shapley Additive exPlanations)은 Shapley 값²⁴⁾과

24) 협조적 게임 이론의 균형은 수익분배협사의 각 당사자들이 협력하여 얻어낸 이익에 각자 얼마나 공헌했

관련이 있으며 특정변수가 예측결과에 공헌한 값을 의미하며 특성변수의 중요도에 대한 가중치인 것이다.



Feature 0 = '중량', Feature 1 = '건수_국가', Feature 2 = '중량_국가', Feature 3 = '결과_국가', Feature 4 = '부적합률_국가', Feature 5 = '건수_유형', Feature 6 = '중량_유형', Feature 7 = '결과_유형', Feature 8 = '부적합률_유형', Feature 9 = '건수_품목국가', Feature 10 = '중량_품목국가', Feature 11 = '결과_품목국가', Feature 12 = '부적합률_품목국가', Feature 13 = 'check']

[그림 4-5] 특성변수의 중요도와 평균 중요도

[그림 4-5]에서와 같이 품목과 국가별 과거 부적합률이 정밀검사의 부적합 예측에 가장 큰 영향을 끼치고 있다.

※지를 정의한 후 이에 대한 분배 수 값

제 5 장

결론 및 제언

5

결론 및 제언 <<

빅데이터와 인공지능을 핵심으로 하는 지능정보기술은 현재 우리 삶의 다양한 분야에 보편적으로 활용되어 새로운 가치를 창출하고 있다. 인공지능 기술은 컴퓨터가 인간과 같은 지능적인 방식으로 학습할 수 있도록 하는 것을 목적으로 여러 분야에서 다양한 문제를 해결하고 있다. 통합식품안전정보망을 통해 시·군·구 및 시·도의 축산물 식품안전정보에 대한 전산정보 수집은 이루어졌다. 담당 위생감시원은 그동안 축적된 축산물 안전정보를 단순평균 혹은 비율 등을 기초로 하여 개인의 관찰과 경험으로 위생점검 단속 활동을 수립·시행하고 있다. 수입식품의 신고현황 및 국내 식품영업자의 업소 수는 증가 추세이나 활용 가능한 공무원의 인력 등 자원은 한정적이라 부적합 수입신고 및 부적합업체를 단속하기 위한 효율적인 위생감시 체계의 마련이 필요하다.

본 연구의 목적은 최근의 기계학습 분야의 다양한 예측모형을 식품안전정보에 적용하여 업체 특성과 단속 결과에 영향을 미치는 자료를 바탕으로 부적합업체를 단속하는 확률을 예측하는 것이다. 본 연구는 업소별 기본정보, 위반빈도, 과거 행정처분 이력, 생산실적 등을 영업자 위생관리 수준을 평가하고 분석하였다. 위험 수준이 높은 업체에 대한 선택과 집중을 통한 위생 점검 활동을 효율화하였다. ‘부적합’이라고 사

전에 판정하여 위생점검 단속을 나갔을 경우 ‘부적합’으로 판정될 확률이 ‘적발확률’이다. 수입식품의 경우에는 수입신고의 제조국, 품목 유형, 수입업자 및 수입증량 등의 과거 패턴을 분석하여 정밀검사 실시의 필요성에 대한 확률을 산출하였다.

향후에는 본 정책연구용 용역사업의 결과를 바탕으로 통합망의 축산물 안전정보를 자동 추출, 정제(결측치, 이상치 처리) 및 데이터 표준화 등 시스템의 개발을 통해 지속적이고 확대 적용이 가능한 기반을 마련할 수 있기를 기대한다. 예측모형의 고도화를 위해서는 통합식품안전정보망의 식품안전정보의 결측치와 이상치 등 데이터처리의 예외사항에 대한 데이터 정제작업은 최소 1년 단위로 실시되어야 한다.

부적합 업체를 단속하는 업소별 ‘적발확률’은 분석 자료의 품질에 크게 좌우되기에 데이터의 검증 및 정제를 위한 절차의 수립과 시행이 필요하다. 향후 단속 활동의 결과로 축적될 데이터의 분포 및 패턴의 변동성은 예측 모형의 변동 가능성을 필연적으로 발생시키게 된다. 과거 데이터의 분포가 향후 축적될 데이터의 분포가 차이가 있을 수 있어 위생 점검에 영향을 미치는 입력변수의 변동성 분석, 최적 예측모형의 선정·평가 작업은 식약처 담당 공무원과 관련 전문가를 통해 이루어져야 한다. 축적되는 자료의 증가로 입력변수가 달라질 수도 있고, 예측모형 자체 혹은 예측모형의 파라미터 등이 달라질 수 있기때문에 이에 대한 절차 및 프로세스를 수립하여 연차별 혹은 반기별로 수행하여야 한다.

국내와 수입, 농·축·수산물과 가공식품의 데이터 특성에 따라 차별화

되는 입력변수의 선정 및 분석 작업은 식약처의 담당과에서 수행하고 데이터 관점에서 통합하는 역할과 기능을 하는 조직의 신설 혹은 기존 조직에 역할을 부여하여 지속적으로 운영하고 고도화하기 위한 노력이 필요하다.

참고 문헌

- 김용대. (2007). 기계학습과 통계학. *정보과학회지*, 25(3), pp. 90-95.
- 김현수. (2003). 비통계적 링크분석을 활용한 보험사기의 효과적 적발방법 연구. 보험연구원
- 이장우, 권세왕. (2011). Maximum Expected Utility를 이용한 중소기업 부도 예측모형 연구. *한국증권학회지*, 40(5), pp. 775-799.
- 이화경, 한상범, 지원철. (2010). 신용카드 불법현금유통 적발을 위한 축소된 앙상블 모형. *지능정보연구*, 16(1), pp. 93-116.
- 조상구, 최경현 (2018) 수입식품 빅데이터를 이용한 부적합식품 탐지시스템에 관한 연구, *한국빅데이터학회지*, 3(2), pp. 19-33
- Abhitav Srivastava, Amlat Kutdu, Shamik Sural Arut, K. Majumdar. (2008). Credit Card Fraud Detectiot Usitg Hiddet Markov Model. *IEEE Tratsactiots ot Depetdable atd Secure Computitg*. 5(1), pp. 37-48.
- Authors Saito, Takaya, Rehmsmeier, Marc. (2015). The Precision-Recall Plot Is More Informative than the ROC Plot When Evaluating Binary Classifiers on Imbalanced Datasets Source *PLOS ONE*, 10(3). p. 21.
- Fu, G. Yi, L., Pan, n. (2018). Tuning model parameters in class-imbalanced learning with precision-recall curve, *Biometrical Journal*. (In Press).
- Petg Y, Kou G, Sabatka A, Chet Z, Khazatchil D and Shi Y. (2006). Applicatiot Of clusteritg methods to health itsuratce fraud detectiot. *Itt Cotf Serv Syst Serv Matag*, 1, pp. 116-120.
- Yitg Watg, Michael Campbell. (2010). Busitess Failure Predictiot for Publicly Listed Compaties it Chita. *Journal of Busitess atd Matagemett*. 16(1), pp. 75-88
- Zohar, D. (2011). Safety Climate: Cotceptual atd Measuremett Issues. It: Quic JC, Tetrick LE, editors. *Handbook of Occupatiotal Health*

Psychology. Washitgot, DC: Americat Psychological Associatior

Saito, T and Rehmsmeier, M.. (2015). Precision-Recall Plot Is More Informative than the ROC Plot When Evaluating Binary Classifiers on Imbalanced Datasets, *PLOS ONE*, 10(3), p. 21.

Hands-on Machine Learning with Scikit-Learn, Keras & Tensorflow, 2nd Edition, , O'RELLY, Aurlien Geron

Python Data Science Hanbook, O'RELLY, Jake VanderPlas

INtroduction to Machine Learning with Python, O'RELLY, Andreas. Muller & Sarah Guido

Python Machine Learning, PACKT, Sebastian Raschka

<https://seaborn.pydata.org/tutorial/categorical.html>

<https://seaborn.pydata.org/tutorial.html>

<https://github.com/corazzon/OpenDataWrangling/blob/master/park.ipynb>

<https://www.kaggle.com/janiobachmann/credit-fraud-dealing-with-imbalanced-datasets/notebook>

https://www.youtube.com/watch?v=ZUF4XrUArg0&list=PLbhbGI_ppZIRPeAjprW9u9A46IJlGFdLn&index=41

<https://ratsgo.github.io/machine%20learning/2017/04/24/PCA>

<https://manisha-sirsat.blogspot.com/2019/04/confusion-matrix.html?fbclid=IwAR37gOuOpCCLlqoY1d39OiD3w30h6yjrIwA0ekQJb-dcOABGwVMqiFjiX8>

<https://www.kaggle.com/c/home-credit-default-risk>

<https://www.kaggle.com/willkoehrsen/start-here-a-gentle-introduction>

<http://www-bcf.usc.edu/~gareth/ISL/>

<https://www.r-bloggers.com/in-depth-introduction-to-machine-learning>

-in-15-hours-of-expert-videos/

<https://www.kaggle.com/willkoehrsen/introduction-to-manual-feature-engineering>

<https://www.kaggle.com/willkoehrsen/introduction-to-manual-feature-engineering-p2>

<https://www.kaggle.com/willkoehrsen/clean-manual-feature-engineering>

<https://www.analyticsvidhya.com/blog/2017/08/introduction-to-multi-label-classification/>

<https://datascience.stackexchange.com/questions/29051/is-correlation-needed-when-building-a-model>

<https://www.youtube.com/watch?v=uJ6QO6jLBWA>

<https://www.data.go.kr/dataset/15012890/standard.do>

<https://github.com/corazzon/OpenDataWrangling>

<https://github.com/corazzon/OpenDataWrangling/blob/master/park.ipynb>

<https://datascience.stackexchange.com/questions/6547/open-source-anomaly-detection-in-python>

<https://github.com/yzhao062/Pyod>

https://pyod.readthedocs.io/en/latest/examples.html#module-examples.knn_example

https://pyod.readthedocs.io/en/latest/_modules/examples/feature_bagging_example.html#visualize

https://scikit-learn.org/stable/auto_examples/cluster/plot_kmeans_silhouette_analysis.html#sphx-glr-auto-examples-cluster-plot-kmeans-silhouette-analysis-py

https://scikit-learn.org/stable/auto_examples/semi_supervised/plot_label_propagation_digits.html#sphx-glr-auto-examples-semi-supervised-label-propagation-digits

d-plot-label-propagation-digits-py

https://scikit-learn.org/stable/auto_examples/semi_supervised/plot_label_propagation_versus_svm_iris.html#sphx-glr-auto-examples-semi-supervised-plot-label-propagation-versus-svm-iris-py

<https://www.kaggle.com/altprof/basic-semi-supervised-learning-models>

<https://www.kaggle.com/rizwanse/20-ml-algorithms-15-plot-for-beginners>

<https://www.kaggle.com/janiobachmann/credit-fraud-dealing-with-imbalanced-datasets>

<https://www.kaggle.com/rafjaa/resampling-strategies-for-imbalanced-datasets/notebook>

<https://github.com/scikit-learn-contrib/imbalanced-learn>

https://imbalanced-learn.readthedocs.io/en/stable/over_sampling.html

<http://www.jblumenstock.com/files/courses/econ174/FEModels.pdf>

<https://www.kaggle.com/willkoehrsen/a-complete-introduction-and-walkthrough/notebook>

<https://www.youtube.com/watch?v=ErDgauqnTHk>

<https://ratsgo.github.io/machine%20learning/2017/04/24/PCA/>

https://www.youtube.com/watch?v=ZUF4XrUArg0&list=PLbhbGI_ppZIRPeAjprW9u9A46IJlGFdLn&index=41

https://en.wikipedia.org/wiki/Expectation%E2%80%93maximization_algorithm

<https://www.kaggle.com/wrosinski/shap-feature-importance-with-feature-engineering>

<https://www.kaggle.com/kernels/scriptcontent/5525515/download>

<https://towardsdatascience.com/smarter-ways-to-encode-categorical-data-for-machine-learning-part-1-of-3-6dca2f71b159>

<https://maxhalford.github.io/blog/target-encoding-done-the-right-way/>

<https://medium.com/@pouryaayria/k-fold-target-encoding-dfe9a594874b> (K-fold target encoding)

<https://pdfs.semanticscholar.org/1d10/6a2730801b6210a67f7622e4d192bb309303.pdf>

